PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS
NÚCLEO DE EDUCAÇÃO A DISTÂNCIA
Pós-graduação *Lato Sensu* em Ciência de Dados e Big Data

Marcelo Joventino Freitas

CLASSIFICAÇÃO DA ATIVIDADE ECONÔMICA SPED EFD-CONTRIBUIÇÕES UTILIZANDO A DESCRIÇÃO DOS SERVIÇOS PRESTADOS

Vitória
2021

Marcelo Joventino Freitas

CLASSIFICAÇÃO DA ATIVIDADE ECONÔMICA SPED EFD-CONTRIBUIÇÕES UTILIZANDO A DESCRIÇÃO DOS SERVIÇOS PRESTADOS

Trabalho de Conclusão de Curso apresentado ao Curso de Especialização em Ciência de Dados e Big Data como requisito parcial à obtenção do título de especialista.

Vitória
2021

SUMÁRIO

1. Introdução

1.1. Contextualização

A Escrituração Fiscal Digital Contribuições (EFD Contribuições) trata de arquivo digital instituído no Sistema Público de Escrituração Digital (SPED), a ser utilizado pelas pessoas jurídicas de direito privado na escrituração da Contribuição Previdenciária sobre a Receita Bruta (CPRB), da Contribuição para o PIS/Pasep e da Cofins, com base nas operações representativas de receitas auferidas, custos e despesas.

Foi instituído um código de atividade para cada tipo de serviço ou produto sujeito à CPRB, utilizado na apuração do valor da CPRB no bloco P100 da EFD-Contribuições. As tabelas de alíquotas da EFD-Contribuições são montadas a partir deste código.

A apuração no bloco P100 é feita com base nas receitas de venda de produtos e serviços contidos nos blocos C170 e A170 de forma manual.

Há dificuldade na associação dos serviços contidos no bloco A170 com a atividade econômica do bloco P100, principalmente quando há mais de um tipo de serviço prestado no período analisado, pois essa etapa é feita manualmente.

1.2. O problema proposto

O problema proposto é aferir o código de atividade econômica a ser informado no bloco P100 da EFD-Contribuições a partir da descrição do serviço informada no bloco A170 da EFD-Contribuições.

A descrição do serviço no bloco A170 também pode conter a classificação do serviço com base na Lei Complementar 116 de 31/07/2003.

2. Coleta de Dados

A coleta de dados foi feita na base A170 (descrição dos serviços) para os declarantes de 1 código de atividade na base P100 do SPED EFD-Contribuições no

período entre os anos 2016 e 2020. Os registros foram rotulados com o código de atividade informado na base P100.

Foi escolhido o mês de janeiro, abril e setembro para montagem do dataset de treino, e o mês de junho para o dataset de validação, aplicando-se amostragem aleatória para obtenção de classes balanceadas.

Os datasets possuem a seguinte estrutura:

Nome da coluna	**Descrição**	**Tipo**
ativ	Código da atividade econômica (alvo)	Inteiro
cd_lc	Código do serviço pela LC 116	Texto
desc_it	Descrição do serviço	Texto

3. Processamento/Tratamento de Dados

Primeiramente identificou-se os declarantes na base P100 da EFD-Contribuições com somente 1 código de atividade econômica informado no ano em análise. Esse código de atividade foi usado como rótulo na base A170 da EFD-Contribuições com as descrições de serviço informadas.

Foram então consultados os registros de descrição do serviço da base A170 para aqueles declarantes selecionados inicialmente. As consultas foram realizadas nos meses de janeiro, abril, junho e setembro de 2016 a 2020, separando-se o mês junho para validação. Foi aplicada uma amostragem aleatória com o objetivo de separar 16 mil amostras para cada classe no dataset de treino:

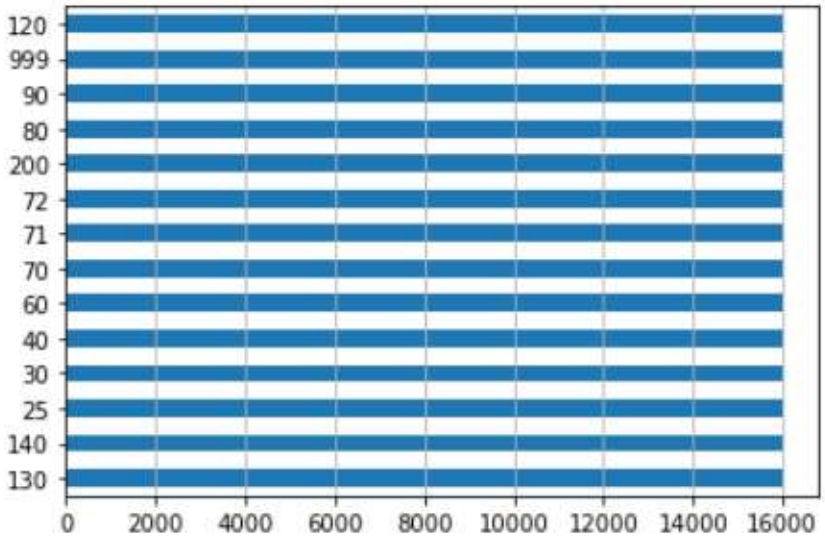

Os registros das classes 91 a 98 foram agrupados na classe 90 (construção civil). Foi criada a classe 999 de registros que não pertencem a nenhuma das outras classes em estudo.

Foram separados 1000 registros de cada classe para o dataset de validação no mês de junho.

As descrições de serviço com erro de leitura por conta de acentos e caracteres especiais foram excluídos em virtude da quantidade não ser significativa.

Foi efetuada a limpeza do campo descrição com as seguintes ações:

a) Remoção de pontuação;

b) Remoção de caracteres numéricos;

c) Remoção de stopwords;

d) Remoção de palavras com 1 caracter

O campo com o código da lei complementar 116 teve apenas a remoção de pontuação e a manutenção do código numérico.

Foi criado o campo ‘texto_limpo’ com o código da lei complementar 116 + descrição após a limpeza.

Foram excluídos os registros do dataset de treino quando:

a) ‘texto_limpo’ contém ‘call center’ e ‘ativ’ é diferente de 30;

b) ‘texto_limpo’ contém ‘cobranca’ e ‘ativ’ é diferente de 30;

c) ‘texto_limpo’ contém ‘empreitada’ e ‘ativ’ não está em ’90,120’;

d) ‘texto_limpo’ contém ‘subempreitada’ e ‘ativ’ não está em ’90,120’;

e) ‘texto_limpo’ contém ‘construcao’ e ‘ativ’ não está em ’90,120’;

f) ‘texto_limpo’ contém ‘carga’ e ‘ativ’ é igual a 999;

g) ‘texto_limpo’ contém ‘descarga’ e ‘ativ’ é igual a 999;

h) ‘texto_limpo’ contém ‘portuario’ e ‘ativ’ é igual a 999;

i) ‘texto_limpo’ contém ‘praticagem’ e ‘ativ’ é igual a 999;

j) ‘texto_limpo’ contém ‘manutencao’ e ‘ativ’ é igual a 999;

k) ‘texto_limpo’ contém ‘obra’ e ‘ativ’ é igual a 999;

l) ‘texto_limpo’ contém ‘obras’ e ‘ativ’ é igual a 999;

m) ‘texto_limpo’ contém ‘engenharia’ e ‘ativ’ é igual a 999;

n) ‘texto_limpo’ contém ‘transporte’ e ‘ativ’ é igual a 999;

o) ‘texto_limpo’ contém ‘logistica’ e ‘ativ’ é igual a 999;

Foram realizados os seguintes ajustes a partir do campo ‘texto_limpo’:

a) Os registros que ficaram vazios após a limpeza foram substituídos pela palavra ‘servico’;

b) Foram excluídos os registros com ‘ativ’ igual a 999 e a descrição na lista: ‘prestacao servico’, ‘servico’, ‘servicos’, ‘servicos prestados’.

4. Análise e Exploração dos Dados

Foi gerada uma nuvem de palavras com todo o dataset de treino:

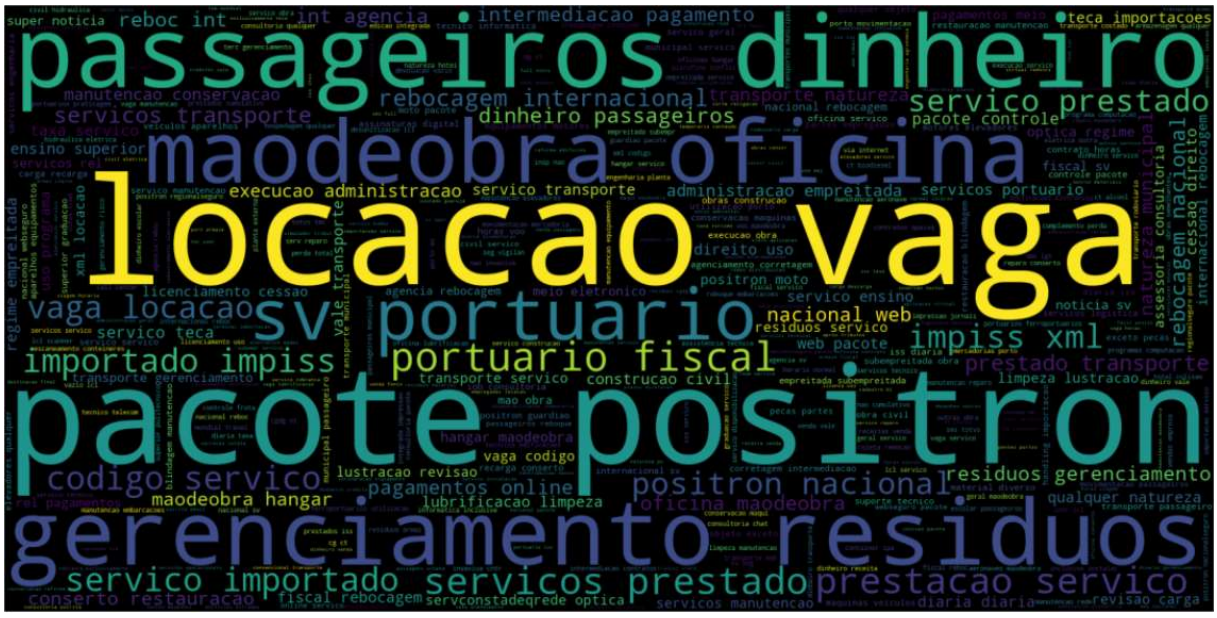

E identificados os unigramas e bigramas mais frequentes:

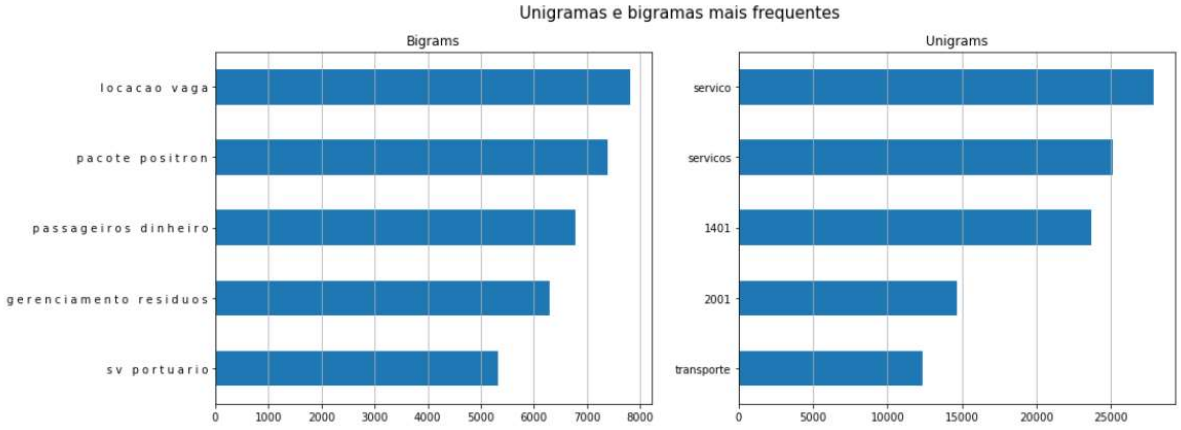

Também foram identificados os unigramas e bigramas mais frequentes por classe:

a) Classe 25 – serviços de TI:

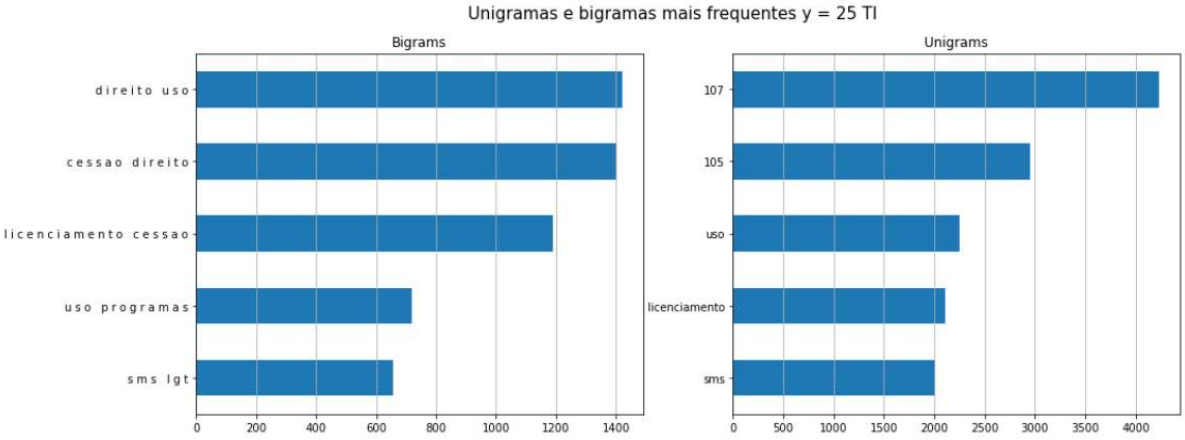

a) Classe 30 – serviços de call center:

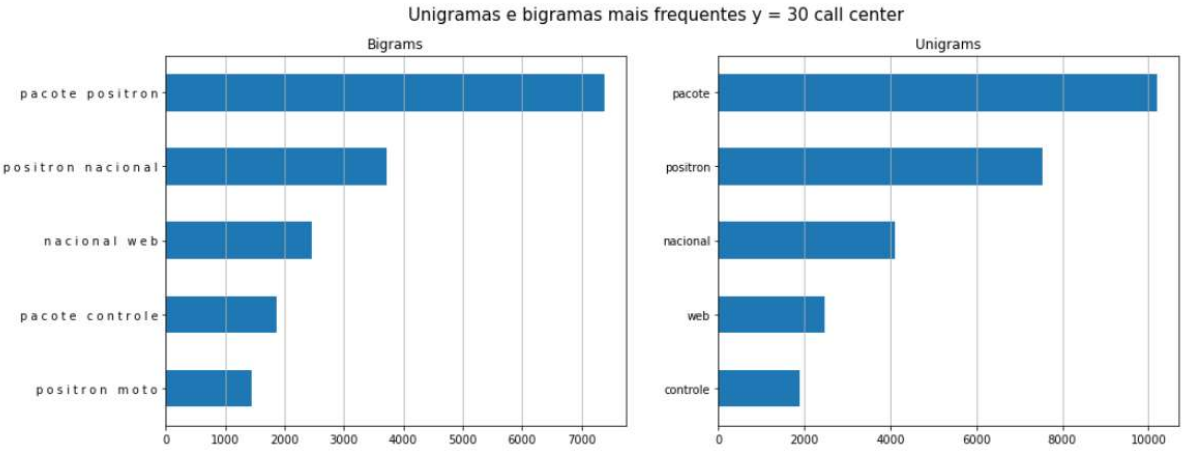

b) Classe 40 – setor hoteleiro:

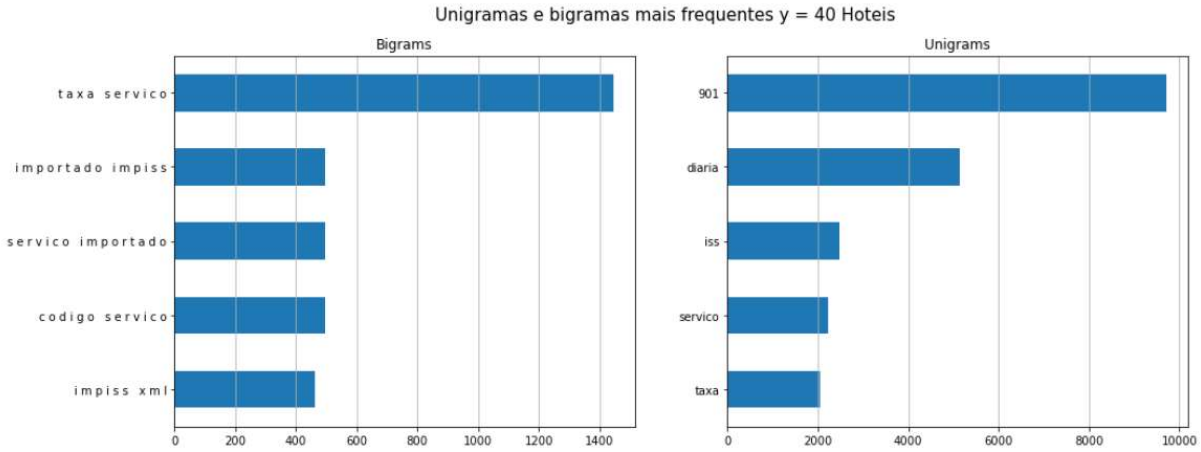

c) Classe 60 – transporte rodoviário coletivo de passageiros:

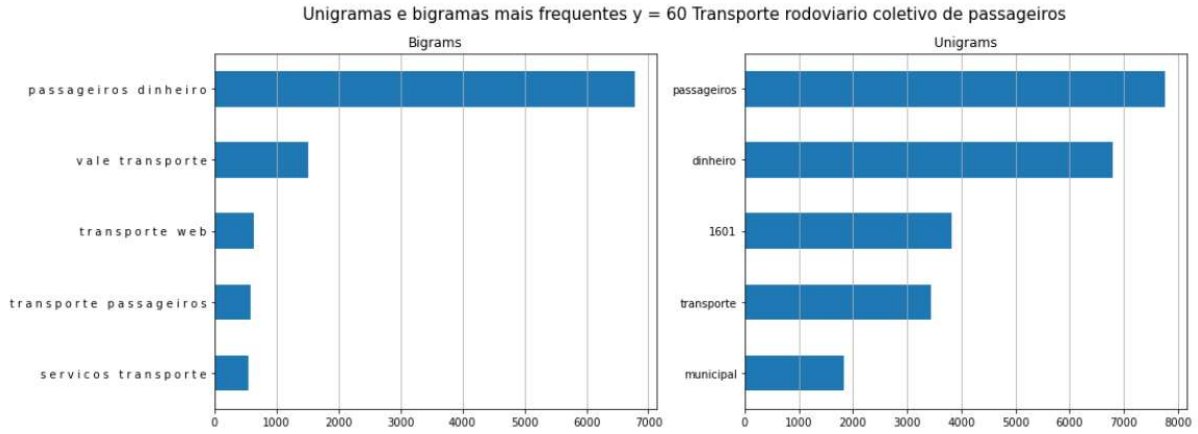

d) Classe 70 – transporte aéreo e marítimo:

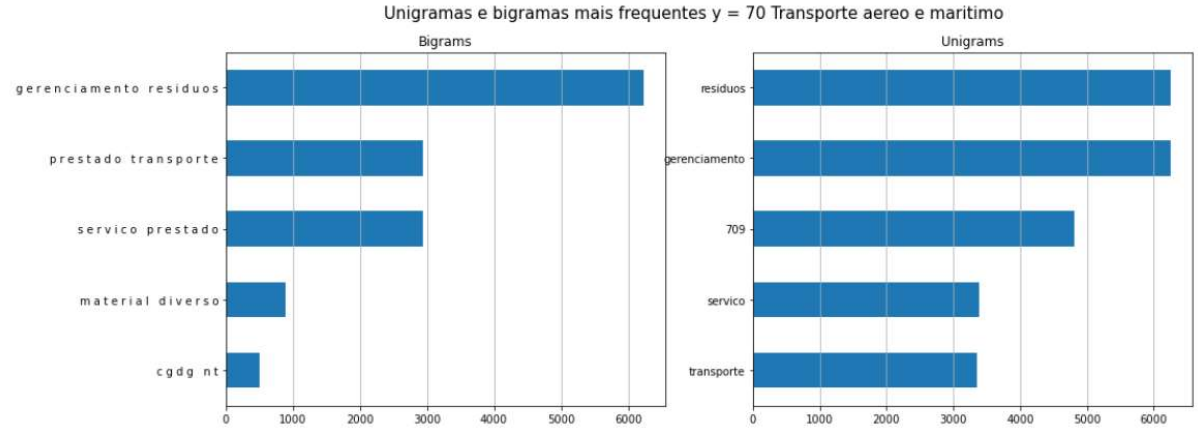

e) Classe 71 – manutenção e reparação de aeronaves:

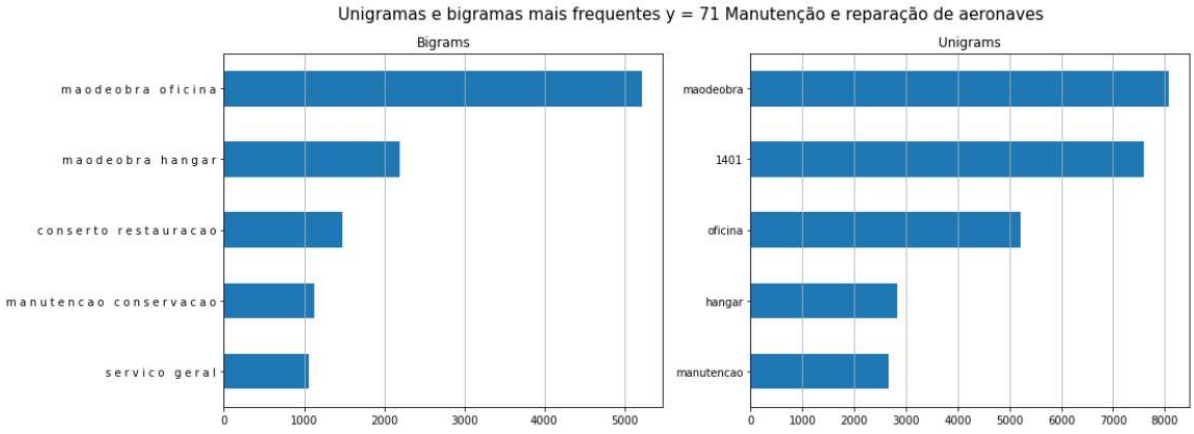

f) Classe 72 – apoio marítimo e portuário:

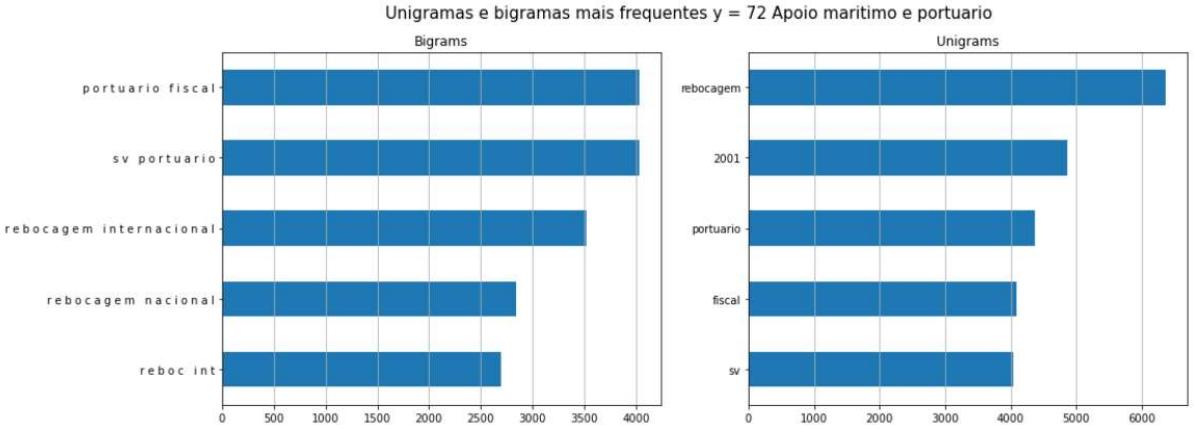

g) Classe 80 – manutenção e reparação de embarcações:

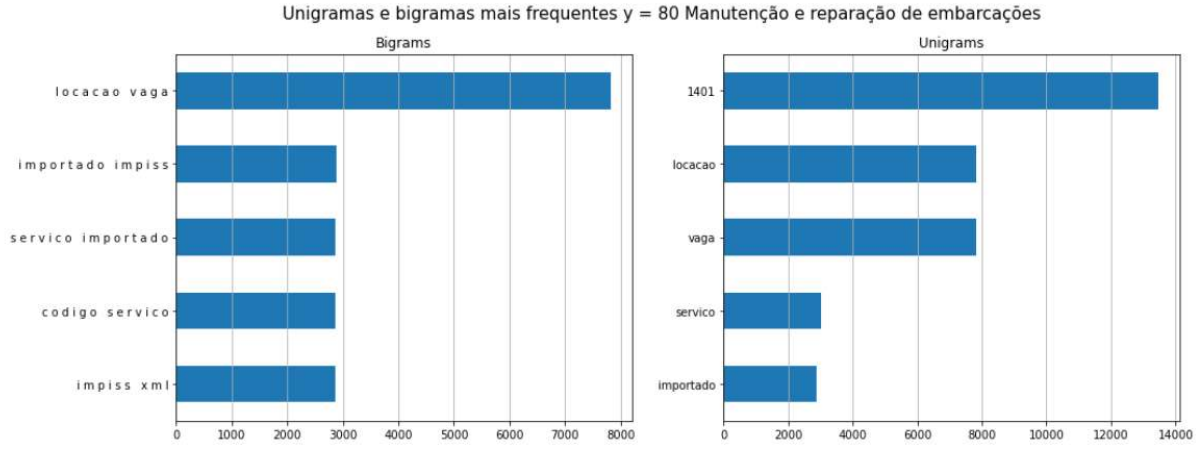

h) Classe 90 – construção civil:

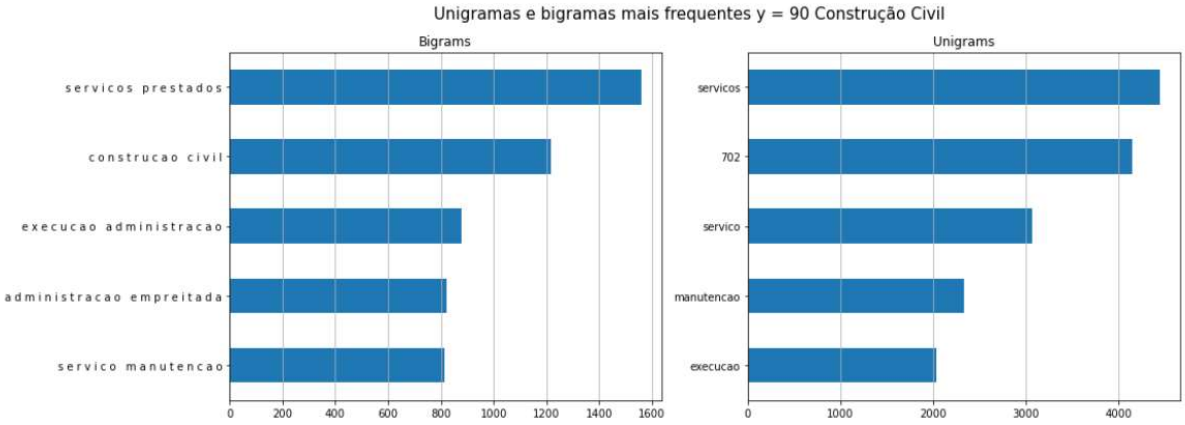

i) Classe 120 – obras de infraestrutura:

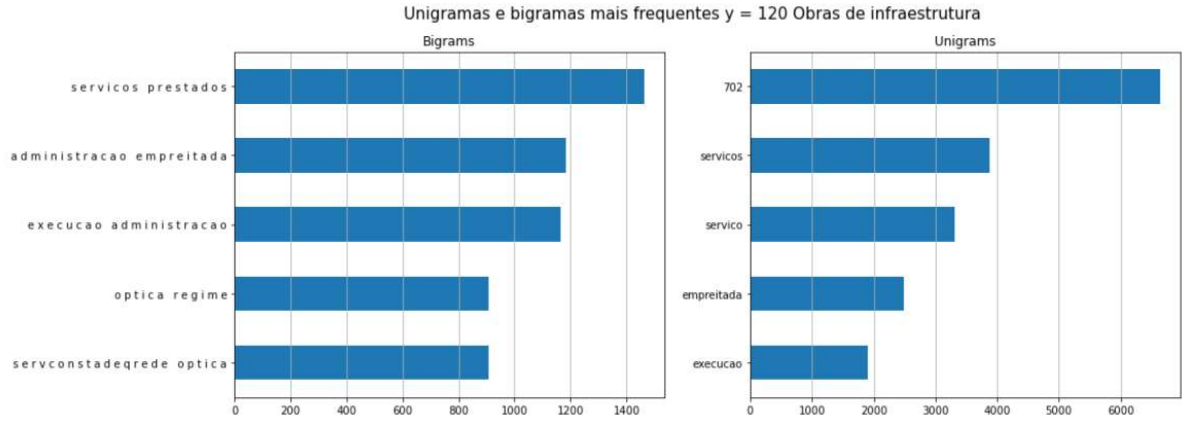

j) Classe 130 – carga, descarga e armazenagem:

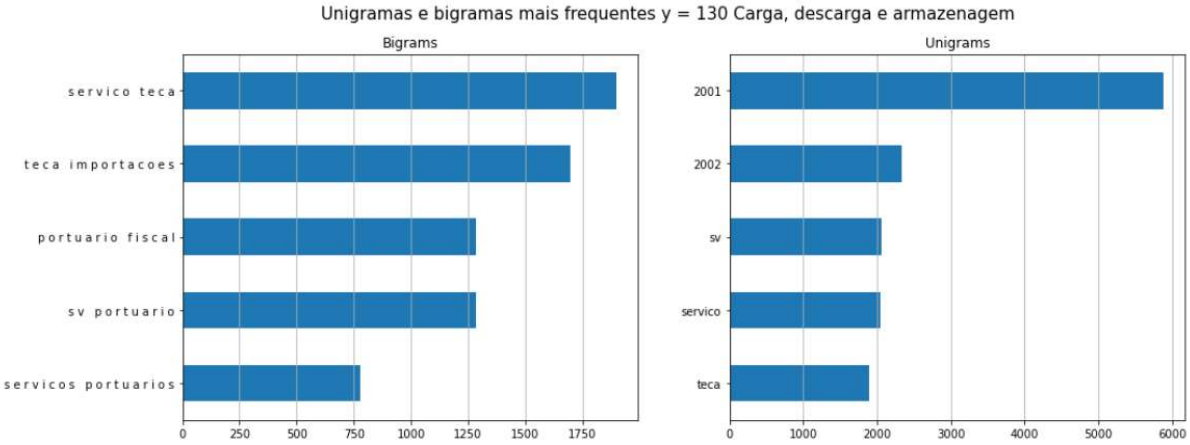

k) Classe 140 – transporte rodoviário de cargas:

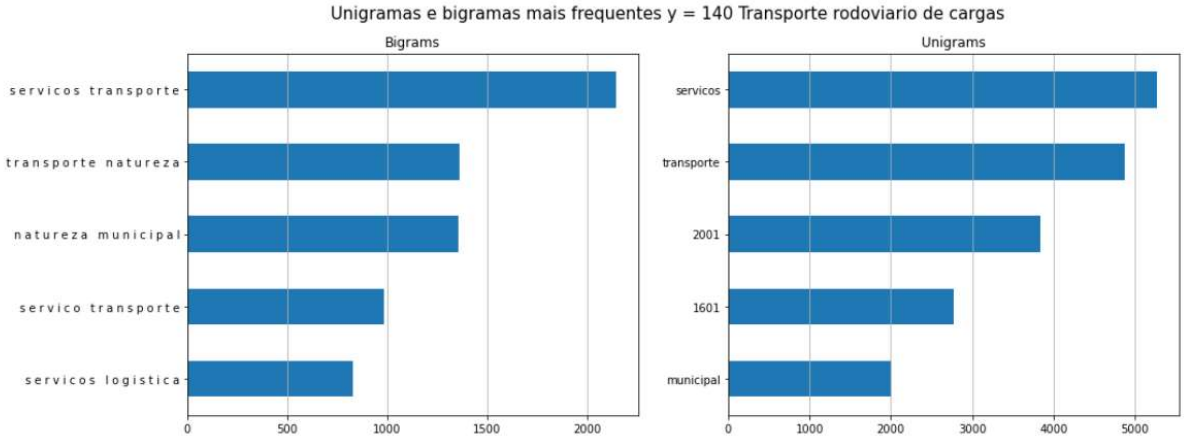

I) Classe 200 – jornais, rádios e televisão:

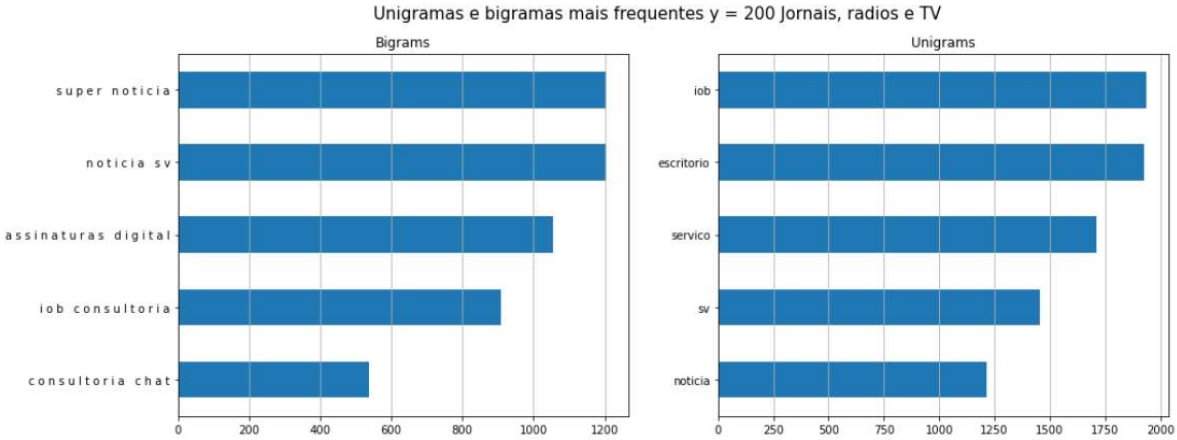

Distribuição da contagem de palavras por registro do dataset de treino:

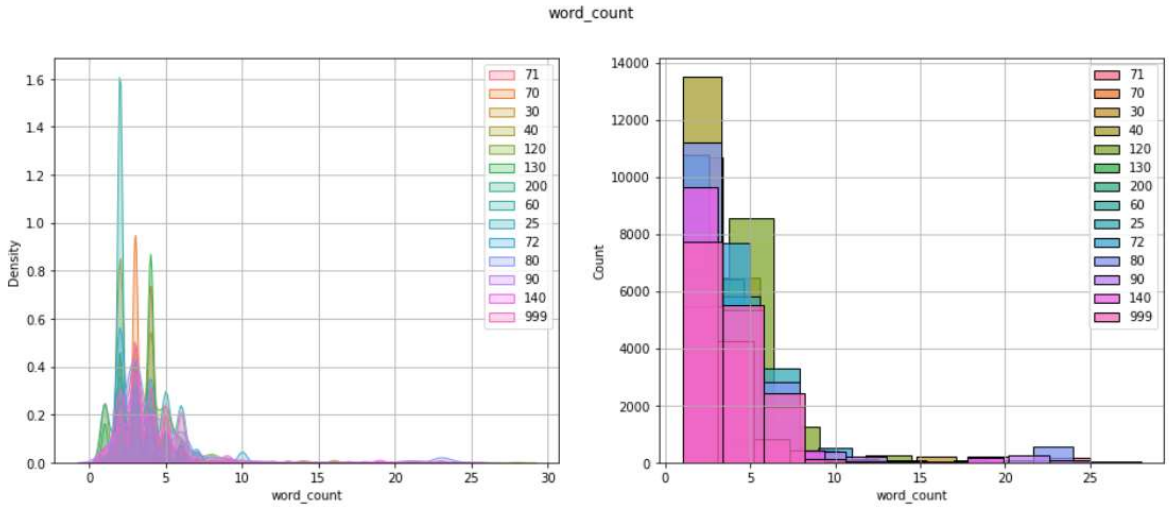

Distribuição da contagem de caracteres por registro do dataset de treino:

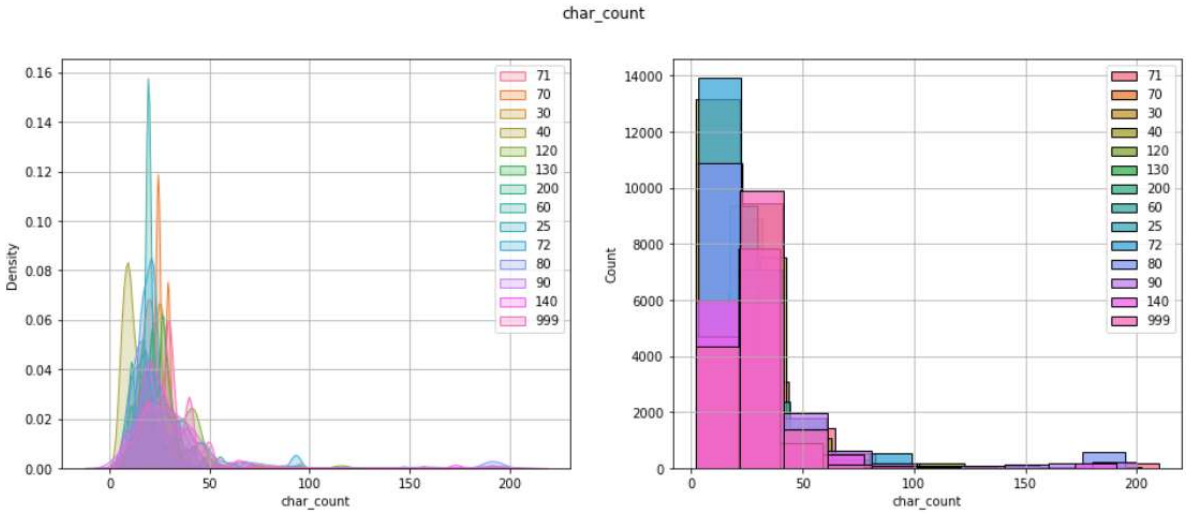

5. Criação de Modelos de Machine Learning

Foram instanciados vários métodos de vetorização de documentos para avaliação da melhor adequação ao problema analisado para unigramas e bigramas:

a) Binária: palavras são marcadas como presentes (1) ou ausentes (0);
b) Contagem: contagem de ocorrências de cada palavra como um número inteiro;
c) Frequência: frequência de cada palavra no documento;
d) Tfidf: frequência das palavras com penalização das palavras mais comuns (frequência + grau de raridade);
e) Hash: frequência das palavras com limitação das features (colunas) na matriz de vetores (versão sklearn);

In [38]:
```
# unigramas
binary_vectorizer = CountVectorizer(binary=True)
count_vectorizer = CountVectorizer()
freq_vectorizer = TfidfVectorizer(use_idf=False)
tfidf_vectorizer = TfidfVectorizer()
hashing_vectorizer = HashingVectorizer(n_features = 2 ** 11)

# bigramas
binary_vectorizer2 = CountVectorizer(binary=True, ngram_range=(1,2))
count_vectorizer2 = CountVectorizer(ngram_range=(1,2))
freq_vectorizer2 = TfidfVectorizer(use_idf=False, ngram_range=(1,2))
tfidf_vectorizer2 = TfidfVectorizer(ngram_range=(1,2))
hashing_vectorizer2 = HashingVectorizer(n_features = 2 ** 11, ngram_range=(1,2))
```

f) Teste qui-quadrado: função que determina quais palavras são estatisticamente relevantes, mantendo aquelas com significância de 95%:

```python
def teste_chi2(docs=None, y=None, vectorizer=None, p_value_limit = 0.95):
        ''' chi-squared test to dermine whether a feature and target are independent - statistically relevant
            keep only features with p_value_limit = 0.95 '''
        X = vectorizer.fit_transform(docs)
        X_names = vectorizer.get_feature_names()
        print('tamanho_vocabulario = ', len(vectorizer.vocabulary_))
        print(X.shape)
        df_features = pd.DataFrame()
        for cat in np.unique(y):
            chi2_, p = chi2(X, y == cat)
            df_features = df_features.append(pd.DataFrame({'feature': X_names, 'score': 1-p, 'y': cat}))
        df_features = df_features.sort_values(['y', 'score'], ascending=[True, False])
        df_features = df_features[df_features['score'] > p_value_limit]
        print(df_features.sample(10))
        print('vocab_testado:', df_features.feature.nunique())
        return df_features.feature.unique().tolist()
```

A função seguinte recebe o algoritmo de aprendizagem de máquina e os vetorizadores para montar um DataFrame com os resultados dos testes aplicados. A função também possibilita aplicar uma redução de componentes pelo TruncatedSVD do sklearn:

In [47]:

```python
results_ml = pd.DataFrame(columns = ['acc','precision_macro','recall_macro','f1_macro','mcc'])
def s_results(docs_train, ytrain, vectorizer=None, model=None, svd=None, docs_val=None, yval=None):
    if svd:
        pipe = Pipeline(steps=[('vectorizer', vectorizer),
                               ('svd', TruncatedSVD(n_components=100, n_iter=10, random_state=0)),
                               ('model', model)])
    else:
        pipe = Pipeline(steps=[('vectorizer', vectorizer),
                               ('model', model)])
    pipe.fit(docs_train, ytrain)
    yv_pred = pipe.predict(docs_val)
    acc = accuracy_score(yval, yv_pred)
    p_m = precision_score(yval, yv_pred, average='macro')
    r_m = recall_score(yval, yv_pred, average='macro')
    f1_m = f1_score(yval, yv_pred, average='macro')
    mcc = matthews_corrcoef(yval, yv_pred)
    return pd.Series(data=[acc, p_m, r_m, f1_m, mcc], index=['acc','precision_macro','recall_macro','f1_macro','mcc'])
```

Foram testados os seguintes algoritmos de aprendizagem de máquina:

a) NB: Naive Bayes MultinomialNB;

b) RF: Random Forest;

c) LG: Regressão Logística;

d) SVM: Suport Vector Machines.

E utilizadas as seguintes abreviaturas nas chamadas da função:

a) uni: unigramas;

b) bi: bigramas;

c) chi2: redução de variáveis pelo método qui-quadrado;

d) SVD: redução de variáveis pelo método SVD;

e) Binary: vetorização binária;

f) Count: vetorização por contagem;

g) Freq: vetorização por frequência;

h) Tfidf: vetorização por tfidf;

i) Hash: vetorização hash.

Foram acrescentados blocos de código organizados por: algoritmo, vetorização, unigramas, bigramas, unigramas com teste qui-quadrado, unigramas com SVD, bigramas com teste qui-quadrado, bigramas com SVD. Segue como exemplo o bloco de código com o algoritmo Random Forest vetorizado por frequências:

In [64]:

```
# freq
results_ml.loc['RF_freq_uni'] = s_results(docs_train, ytrain, vectorizer= freq_vectorizer,
                                          model= RandomForestClassifier(random_state=0), docs_val=docs_val, yval=yval)

results_ml.loc['RF_freq_uni_SVD'] = s_results(docs_train, ytrain, vectorizer= freq_vectorizer,
                                              svd=True,
                                          model= RandomForestClassifier(random_state=0), docs_val=docs_val, yval=yval)

results_ml.loc['RF_freq_uni_chi2'] = s_results(docs_train, ytrain, vectorizer= freq_vectorizer_chi2,
                                          model= RandomForestClassifier(random_state=0), docs_val=docs_val, yval=yval)

results_ml.loc['RF_freq_bi'] = s_results(docs_train, ytrain, vectorizer= freq_vectorizer2,
                                          model= RandomForestClassifier(random_state=0), docs_val=docs_val, yval=yval)

results_ml.loc['RF_freq_bi_SVD'] = s_results(docs_train, ytrain, vectorizer= freq_vectorizer2,
                                             svd=True,
                                          model= RandomForestClassifier(random_state=0), docs_val=docs_val, yval=yval)

results_ml.loc['RF_freq_bi_chi2'] = s_results(docs_train, ytrain, vectorizer= freq_vectorizer2_chi2,
                                          model= RandomForestClassifier(random_state=0), docs_val=docs_val, yval=yval)
```

6. Apresentação dos Resultados

O dataset de validação foi montado com 1000 amostras por classe em mês distinto dos registros utilizados para treino do modelo. O DataFrame seguinte foi montado com os resultados dos testes aplicados, tendo sido utilizadas as seguintes métricas do sklearn para comparação dos resultados:

a) acc: accuracy score;

b) precision_macro: precision score com o parâmetro average = macro (calcula a métrica para cada classe e depois a média simples);

c) recall_macro: recall score com o parâmetro average = macro;

d) f1_macro: f1 score com o parâmetro average = macro;

e) mcc: Matthews correlation coefficient.

modelo ML com melhor resultado

```
In [70]:  1  results_ml.sort_values(by=['mcc'], ascending=False).head(20)
```

Out[70]:

	acc	precision_macro	recall_macro	f1_macro	mcc
LG_binary_bi	0.8841	0.8903	0.8841	0.8850	0.8757
LG_count_bi	0.8837	0.8899	0.8837	0.8846	0.8752
SVM_tfidf_bi	0.8822	0.8907	0.8822	0.8835	0.8737
SVM_tfidf_uni_chi2	0.8816	0.8896	0.8816	0.8829	0.8731
SVM_freq_bi	0.8816	0.8900	0.8816	0.8828	0.8731
SVM_tfidf_bi_chi2	0.8816	0.8895	0.8816	0.8828	0.8730
SVM_tfidf_uni	0.8814	0.8894	0.8814	0.8826	0.8729

Regressão Logística com bigramas e vetorização binária teve o melhor resultado. Suport Vector Classification com bigramas vetorizado por tfidf ficou em 3º lugar.

O modelo com a regressão logística foi ainda ajustado com os seguintes hiperparâmetros obtendo-se uma pequena melhora nos scores de avaliação:

```
In [74]:  1  grid_search.best_params_
Out[74]: {'C': 10.0, 'solver': 'sag'}
```

Segue o relatório de classificação do sklearn evidenciando o desempenho por classe do melhor modelo:

```
print(classification_report(yval, yv_pred, digits=4))
```

```
              precision    recall  f1-score   support

          25     0.8300    0.9030    0.8649      1000
          30     0.9850    0.9880    0.9865      1000
          40     0.9834    0.9490    0.9659      1000
          60     0.9692    0.9750    0.9721      1000
          70     0.9739    0.8970    0.9339      1000
          71     0.9836    0.9600    0.9717      1000
          72     0.9385    0.9920    0.9645      1000
          80     0.9930    0.9870    0.9900      1000
          90     0.7807    0.7440    0.7619      1000
         120     0.8961    0.8190    0.8558      1000
         130     0.8312    0.7240    0.7739      1000
         140     0.7120    0.6800    0.6957      1000
         200     0.9690    0.9060    0.9364      1000
         999     0.6535    0.8900    0.7536      1000

    accuracy                         0.8867     14000
   macro avg     0.8928    0.8867    0.8876     14000
weighted avg     0.8928    0.8867    0.8876     14000
```

Complementado pela matriz de confusão (colunas com valores reais e linhas com valores preditos):

```
# matriz de confuso: columns: True,  index:   Predict
cm = confusion_matrix(yval, yv_pred)
pd.DataFrame(data=cm, columns=np.sort(val.y.unique()), index=np.sort(val.y.unique()))
```

	25	30	40	60	70	71	72	80	90	120	130	140	200	999
25	903	6	2	6	0	0	0	0	17	2	0	5	6	53
30	0	988	1	0	0	0	0	0	2	0	0	0	1	8
40	6	0	949	0	0	1	0	0	5	1	0	4	1	33
60	0	0	1	975	0	0	1	0	3	0	0	17	1	2
70	0	0	0	3	897	1	2	0	5	7	21	33	1	30
71	1	0	0	0	0	960	0	0	26	3	0	0	1	9
72	1	0	0	0	0	0	992	0	0	1	4	0	0	2
80	0	0	0	0	2	0	1	987	0	1	0	4	0	5
90	10	0	2	0	1	0	0	6	744	62	0	3	1	171
120	4	1	1	0	0	3	0	0	99	819	1	5	12	55
130	0	0	2	0	7	4	54	0	0	0	724	183	0	26
140	125	5	2	19	7	1	5	0	8	1	119	680	1	27
200	24	0	0	0	1	0	1	0	4	2	0	11	906	51
999	14	3	5	3	6	6	1	1	40	15	2	10	4	890

Percebe-se acima dificuldade de classificação entre as classes 90 e 120; e entre as classes 130 e 140, que pode ser explicado pela própria composição das classes.

As classes 90 e 120 são ligadas à atividade de obras de construção civil, sendo a classe 120 específica na parte de infraestrutura.

As classes 130 e 140 tem em comum o transporte de carga, sendo a classe 130 específica em carga, descarga e armazenagem; e a classe 140 específica em transporte rodoviário de carga.

Os erros de classificação acima também ficam minimizados quando o objetivo for buscar a alíquota aplicável à classe, pois a alíquota da classe 90 é igual à alíquota da classe 120, o mesmo ocorrendo com as classes 130 e 140.

A classe 999 constitui-se de uma amostragem de registros não pertencentes às classes anteriores. A classe 999 foi atribuída quando a limpeza do texto deixou a linha vazia no dataset de validação. Falhas na predição da classe também tem relação ao regime opcional da CPRB. Assim, podemos ter registros de empresas cujo serviço enquadra-se numa das classes acima, mas que não fez opção pelo regime da CPRB no ano.

Dessa forma, considero a acurácia obtida pelo modelo satisfatória, principalmente porque o objetivo do modelo é encontrar a classe do serviço (não é escopo deste trabalho classificar a opção pelo regime da CPRB).

7. Links

Os dados utilizados são de propriedade da Receita Federal do Brasil, e a autorização de utilização não permitiu a disponibilização dos datasets gerados. Dessa forma, serão disponibilizados: o script com criação do modelo, arquivo com o modelo ‘ML_model.pickle’, vocabulário utilizado e script exemplificando o uso do modelo construído para classificar as descrições de serviço como proposto.

Link para o vídeo: https://youtu.be/Azlus0IaVQI

Link para o repositório: https://github.com/mjoventino/cod_atividade_cprb

APÊNDICE

Programação/Scripts

Script em Python com a implementação do modelo preditivo do código de atividade econômica.

Script em Python utilizando o modelo construído para predição da atividade econômica a partir de descrições de serviço digitadas.

Processamento da descrição do serviço de nota fiscal para predição da atividade econômica

```
Foram utilizadas amostras de dias coletados em 4 meses dos anos 2016 a 2020
O mês de junho foi escolhido para teste
Foi utilizada a descrição do serviço + código de serviço da Lei Complementar 116/2003 quando informado
```

```
Conda Env:
conda install -c anaconda pydot           # and graphviz: graph models
conda install -c conda-forge fastparquet  # compression gzip rodou no linux

NLP
conda install -c anaconda nltk
conda install -c anaconda seaborn
conda install -c conda-forge wordcloud
conda install -c anaconda scikit-learn

conda install jupyter
# criar as pastas models e best_models
```

```
# na 1ª execução: download de stopwords
nltk.download('stopwords')
```

In [1]:

```
## for data
import numpy as np
import pandas as pd
import pickle
## for plotting
import matplotlib.pyplot as plt
import seaborn as sns
## for processing
from nltk.corpus import stopwords
from nltk import bigrams
import re
import string
from collections import Counter
from sklearn.decomposition import TruncatedSVD
from sklearn.feature_selection import chi2
from sklearn.preprocessing import OneHotEncoder, LabelBinarizer
from sklearn.pipeline import Pipeline
## for bag-of-words
from wordcloud import WordCloud
#from sklearn.model_selection import train_test_split
from sklearn.feature_extraction.text import CountVectorizer, TfidfVectorizer, HashingVe
## for ML
from sklearn.naive_bayes import MultinomialNB
from sklearn.svm import SVC
from sklearn.ensemble import RandomForestClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score, balanced_accuracy_score, f1_score, precisio
from joblib import dump, load
```

In [2]:

```
d_configuracao = {'display.max_columns': 30,
                  'display.expand_frame_repr': True,
                  'display.max_rows': 120,
                  'display.precision': 2,
                  'display.show_dimensions': True,
                 'display.float_format': '{:,.4f}'.format}

for op, value in d_configuracao.items():
    pd.set_option(op, value)
    print(op, value)
```

```
display.max_columns 30
display.expand_frame_repr True
display.max_rows 120
display.precision 2
display.show_dimensions True
display.float_format <built-in method format of str object at 0x7f48ddd5f730
>
```

In [3]:

```
def add2vocab(doc, vocab):
    tokens = clean_doc(doc, False)
    vocab.update(tokens)

def lc2vocab(doc, vocab):
    l_lc = []
    if doc is not None:
        doc = re.sub(r'[^\w\s]', '', str(doc))
        l_lc.append(doc)
        vocab.update(l_lc)

def add2vocab2(bigramas, vocab2):
    tokens = bigramas.split(',')
    vocab2.update(tokens)

def clean_doc(doc=None, string_=True):
    ''' # turn a doc into clean tokens '''
    # split into tokens by white space
    tokens = doc.split()
    # prepare regex for char filtering
    re_punc = re.compile('[%s]' % re.escape(string.punctuation))
    # remove punctuation from each word
    tokens = [re_punc.sub('', w) for w in tokens]
    # remove remaining tokens that are not alphabetic
    tokens = [word.lower() for word in tokens if not word.isdigit()]
    # filter out stop words
    stop_words = set(stopwords.words('portuguese'))
    stop_words.update(['<br />'])
    tokens = [w for w in tokens if not w in stop_words]
    # filter out short tokens
    tokens = [word for word in tokens if len(word) > 1]
    if string_: return " ".join(tokens)
    else: return tokens

def save_list(lines, filename):
    ''' convert lines to a single blob of text '''
    data = '\n'.join(lines)
    # open file
    file = open(filename, 'w')
    # write text
    file.write(data)
    # close file
    file.close()

def doc_to_line(cols):
    ''' limpa e filtra vocab '''
    lc = cols[0]
    text = cols[1]
    l_text_clean = clean_doc(text, False)
    l_text_clean = [w for w in l_text_clean if w in l_vocab]
    l_lc = list()
    lc_clean = re.sub(r'[^\w\s]', '', str(lc))
    if lc_clean in l_vocab:
        l_lc.append(lc_clean)
        l_lc.extend(l_text_clean)
        return " ".join(l_lc)
    else: return " ".join(l_text_clean)

def doc_to_list(lc, text):
```

```
    ''' limpa e filtra vocab '''
    l_text_clean = clean_doc(text, False)
    l_text_clean = [w for w in l_text_clean if w in l_vocab]
    l_lc = list()
    lc_clean = re.sub(r'[^\w\s]', '', str(lc))
    if lc_clean in l_vocab:
        l_lc.append(lc_clean)
        l_lc.extend(l_text_clean)
        return l_lc
    else: return l_text_clean

def bigram_deep(text_clean):
    l_text = text_clean.split()
    l_bi = list(bigrams(l_text))
    l_bi2 = []
    for tup in l_bi:
        l_bi2.append(tup[0] + ' ' + tup[1])
    l_text.extend(l_bi2)
    return ','.join(l_text)

def text2bigram(text):
    l_text = clean_doc(text, False)
    l_bi = list(bigrams(l_text))
    l_bi2 = []
    for tup in l_bi:
        l_bi2.append(tup[0] + ' ' + tup[1])
    return ','.join(l_bi2)

def drop_dfindex(df, index):
    return df.drop(index=index)

def teste_chi2(docs=None, y=None, vectorizer=None, p_value_limit = 0.95):
        ''' chi-squared test to dermine whether a feature and target are independent -
            keep only features with p_value_limit = 0.95 '''
        #vectorizer = TfidfVectorizer(ngram_range=(1,2))
        #vectorizer.fit(docs)
        #X = vectorizer.transform(docs)
        X = vectorizer.fit_transform(docs)
        X_names = vectorizer.get_feature_names()
        print('tamanho_vocabulario = ', len(vectorizer.vocabulary_))
        print(X.shape)
        df_features = pd.DataFrame()
        for cat in np.unique(y):
            chi2_, p = chi2(X, y == cat)
            df_features = df_features.append(pd.DataFrame({'feature': X_names, 'score'
        df_features = df_features.sort_values(['y', 'score'], ascending=[True, False])
        df_features = df_features[df_features['score'] > p_value_limit]
        print(df_features.sample(10))
        print('vocab_testado:', df_features.feature.nunique())
        return df_features.feature.unique().tolist()
        #return df_features

def load_doc(filename):
    ''' # load doc into memory '''
    # open the file as read only
    file = open(filename, 'r')
    # read all text
    text = file.read()
    # close the file
    file.close()
    return text
```

In [4]:

```
path = r'../data/dataset_ML_treino.parq'
treino = pd.read_parquet(path, engine='auto')
treino.shape
```

Out[4]:

```
(224000, 3)
```

In [5]:

```
# atividades econômicas classificadas pelo código do bloco P100 da EFD-Contribuições (S
# 999: amostras de atividades não listadas
i_classes = treino.y.nunique()
print(treino.shape)
treino.y.value_counts().sort_values().plot(kind='barh', legend=False).grid(axis='x');
```

```
(224000, 3)
```

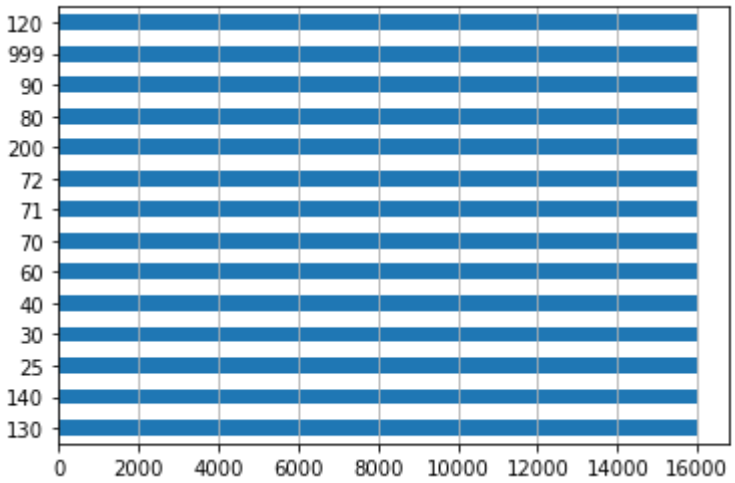

In [6]:

```
# retirar registros do dataset de treino
#treino.loc[treino.text.str.contains('\x80')]
```

In [7]:

```
treino = drop_dfindex(treino, treino.loc[treino.text.str.contains('\x80')].index)
```

In [8]:

```
#treino.loc[treino.text.str.contains('\x87')]
```

In [9]:

```
treino = drop_dfindex(treino, treino.loc[treino.text.str.contains('\x87')].index)
```

In [10]:

```
# montagem do vocabulário unigramas
# limpeza do texto: remoção de pontuação, stopwords, caracteres isolados e números
# foi mantido o nr correspondente ao código da ativiade econômica quando informado
vocab = Counter()
_ = treino.text.apply(lambda x: add2vocab(x, vocab))
_ = treino.cd_lc.apply(lambda x: lc2vocab(x, vocab))
print(len(vocab))
print(vocab.most_common(10))
```

```
10359
[('servico', 27908), ('servicos', 25137), ('1401', 23711), ('2001', 14670),
('transporte', 12317), ('702', 10867), ('pacote', 10224), ('1601', 10023),
('901', 9743), ('manutencao', 9247)]
```

In [11]:

```
# mantém token com uma ocorrência mínima
min_occurrence = 2
l_vocab = [k for k,c in vocab.items() if c >= min_occurrence]
# salva tokens em arquivo texto
save_list(l_vocab, r'../best_models/vocab.txt')

print(len(l_vocab))
```

```
6350
```

In [12]:

```
# bigramas
treino['bigrams'] = treino['text'].apply(lambda x: text2bigram(x))
```

In [13]:

```
# montagem do vocabulário bigramas
# limpeza do texto: remoção de pontuação, stopwords, caracteres isolados e números
vocab2 = Counter()
_ = treino.bigrams.apply(lambda x: add2vocab2(x, vocab2))
del vocab2['']
print(len(vocab2))
print(vocab2.most_common(10))
```

```
21960
[('locacao vaga', 7820), ('pacote positron', 7386), ('passageiros dinheiro',
6787), ('gerenciamento residuos', 6297), ('sv portuario', 5318), ('portuario
fiscal', 5318), ('servicos prestados', 5257), ('maodeobra oficina', 5217),
('codigo servico', 4144), ('servico importado', 4143)]
```

In [14]:

```
# unigramas com limpeza do texto
treino['text_clean'] = treino[['cd_lc','text']].apply(doc_to_line, axis=1)
```

In [15]:

```
# bow: bag of words
unigrams = treino.text_clean
bow = " ".join(unigrams)
```

In [16]:

```
# gerando WordCloud
wordcloud = WordCloud(background_color="black",
                      width=1600, height=800,max_words=400,min_word_length=2).generate(
```

In [17]:

```
# plotando WordCloud
fig, ax = plt.subplots(figsize=(20,10))
ax.imshow(wordcloud, interpolation='bilinear')
ax.set_axis_off()

plt.imshow(wordcloud);
wordcloud.to_file("wordcloud_desc_it.png")
```

Out[17]:

```
<wordcloud.wordcloud.WordCloud at 0x7f48a62fb190>
```

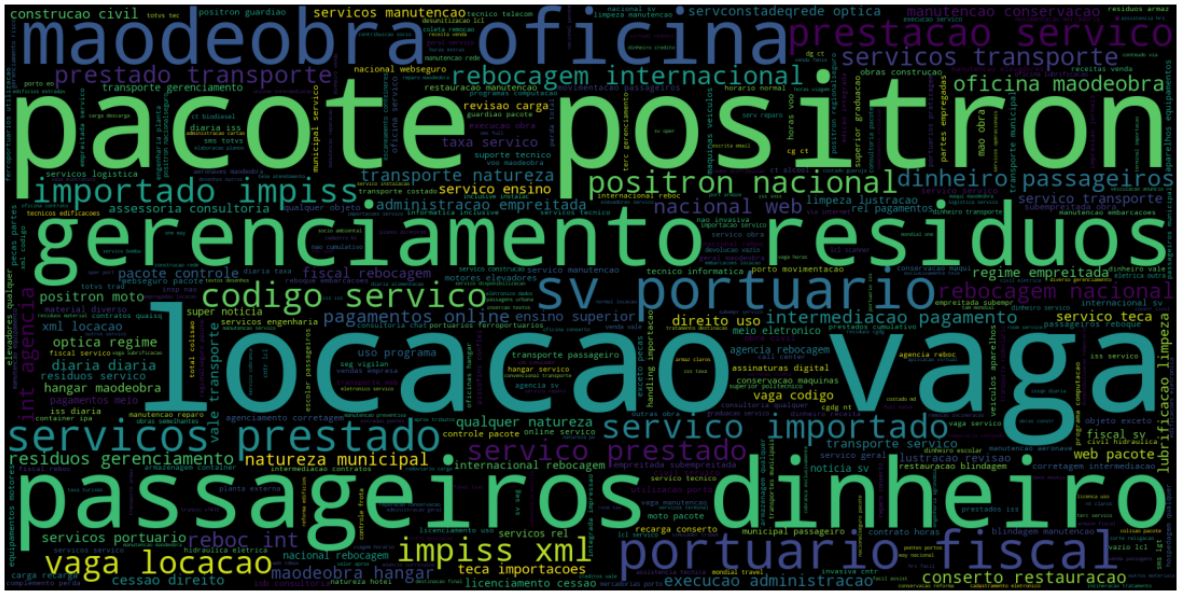

In [18]:

```
# unigramas e bigramas mais frequentes
top = 5
fig, ax = plt.subplots(nrows=1, ncols=2, figsize=(16,6))
fig.suptitle('Unigramas e bigramas mais frequentes', fontsize=15)
## unigrams
df_uni = pd.DataFrame(vocab.most_common(), columns=['word','freq'])
df_uni.set_index('word').iloc[:top,:].sort_values(by='freq').plot(kind='barh', title='U
                                                                  legend=False).grid(axi
ax[1].set(ylabel=None)
## bigrams
df_bi = pd.DataFrame(vocab2.most_common(), columns=['word','freq'])
df_bi.word = df_bi.word.apply(lambda x: ' '.join(string for string in x))
df_bi.set_index('word').iloc[:top,:].sort_values(by='freq').plot(kind="barh", title="Bi
                                                                  legend=False).grid(axi
ax[0].set(ylabel=None)
```

Out[18]:

```
[Text(0, 0.5, '')]
```

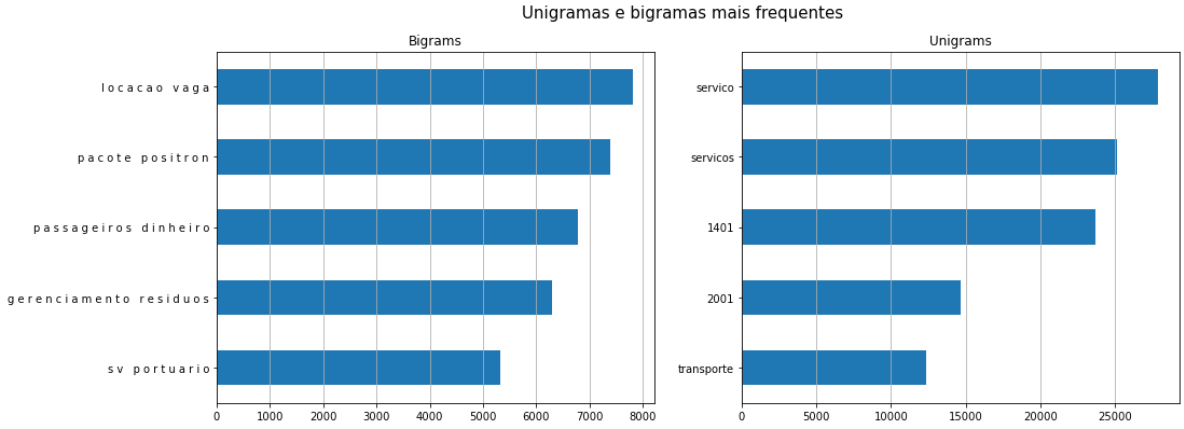

In [19]:

```
def plot_uni_bigramas(y, desc):
    ''' plota unigramas e bigramas de classe '''
    # vocab unigramas
    vocab_y = Counter()
    _ = treino.loc[treino.y == y].text.apply(lambda x: add2vocab(x, vocab_y))
    _ = treino.loc[treino.y == y].cd_lc.apply(lambda x: lc2vocab(x, vocab_y))
    print('Tamanho vocabulario unigramas:',len(vocab_y))
    print('Unigramas mais comuns:',vocab_y.most_common(10))
    # vocab bigramas
    vocab_y2 = Counter()
    _ = treino.loc[treino.y == y].bigrams.apply(lambda x: add2vocab2(x, vocab_y2))
    del vocab_y2['']
    print('Tamanho vocabulario bigramas:',len(vocab_y2))
    print('Bigramas mais comuns',vocab_y2.most_common(10))
    fig, ax = plt.subplots(nrows=1, ncols=2, figsize=(16,6))
    fig.suptitle('Unigramas e bigramas mais frequentes y = ' + str(y) + ' ' + desc , fo
    ## unigrams
    df_uni = pd.DataFrame(vocab_y.most_common(), columns=['word','freq'])
    df_uni.set_index('word').iloc[:top,:].sort_values(by='freq').plot(kind='barh', titl
                                                                      legend=False).gric
    ax[1].set(ylabel=None)
    ## bigrams
    df_bi = pd.DataFrame(vocab_y2.most_common(), columns=['word','freq'])
    df_bi.word = df_bi.word.apply(lambda x: ' '.join(string for string in x))
    df_bi.set_index('word').iloc[:top,:].sort_values(by='freq').plot(kind="barh", title
                                                                      legend=False).gric
    ax[0].set(ylabel=None)
```

In [20]:

```
plot_uni_bigramas(25, 'TI')
```

```
Tamanho vocabulario unigramas: 2520
Unigramas mais comuns: [('107', 4228), ('105', 2957), ('uso', 2250), ('licen
ciamento', 2108), ('sms', 2008), ('servicos', 1944), ('103', 1747), ('cessa
o', 1715), ('101', 1492), ('direito', 1443)]
Tamanho vocabulario bigramas: 4440
Bigramas mais comuns [('direito uso', 1420), ('cessao direito', 1401), ('lic
enciamento cessao', 1189), ('uso programas', 720), ('sms lgt', 658), ('progr
amas computacao', 651), ('servicos prestados', 634), ('uso programa', 623),
('programa computacao', 588), ('sms totvs', 531)]
```

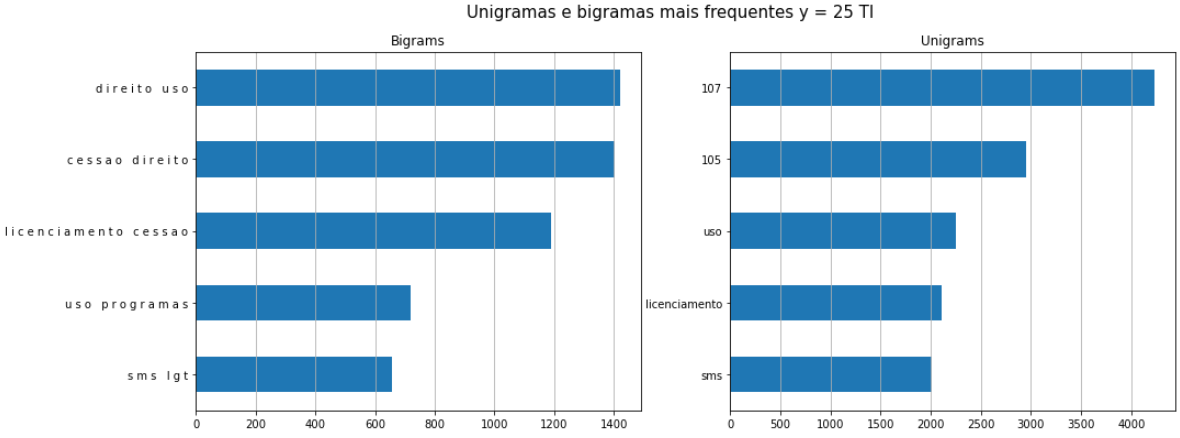

In [21]:

```
1 plot_uni_bigramas(30, 'call center')
```

```
Tamanho vocabulario unigramas: 820
Unigramas mais comuns: [('pacote', 10196), ('positron', 7536), ('nacional',
4110), ('web', 2484), ('controle', 1895), ('moto', 1456), ('1701', 1274),
('webseguro', 1097), ('guardiao', 903), ('servico', 872)]
Tamanho vocabulario bigramas: 1203
Bigramas mais comuns [('pacote positron', 7386), ('positron nacional', 372
6), ('nacional web', 2457), ('pacote controle', 1872), ('positron moto', 144
4), ('nacional webseguro', 1097), ('positron guardiao', 903), ('assessoria c
onsultoria', 599), ('positron regionalseguro', 557), ('complemento perda', 5
26)]
```

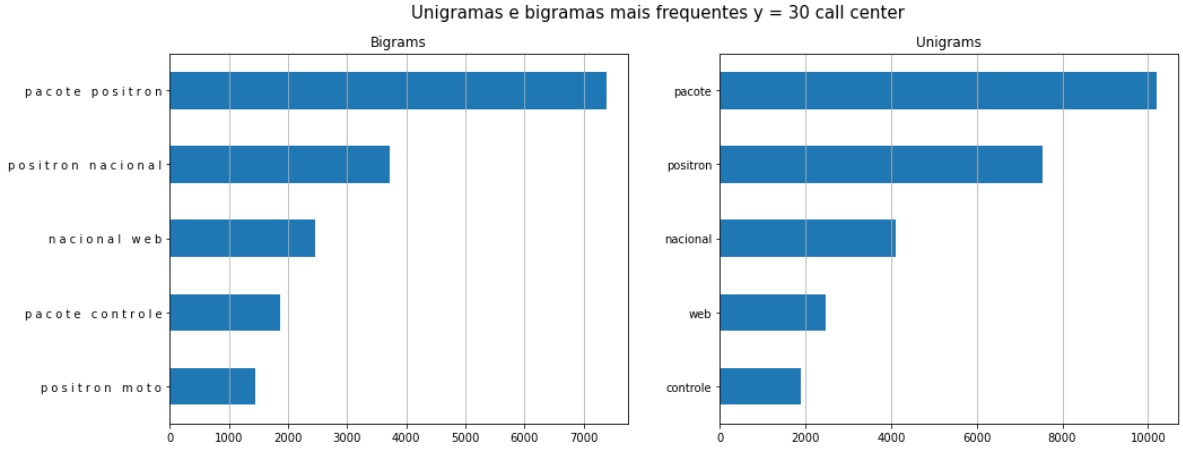

In [22]:

```
1 plot_uni_bigramas(40, 'Hoteis')
```

```
Tamanho vocabulario unigramas: 694
Unigramas mais comuns: [('901', 9707), ('diaria', 5152), ('iss', 2489), ('se
rvico', 2228), ('taxa', 2054), ('hospedagem', 1015), ('servicos', 719), ('di
arias', 698), ('room', 653), ('turismo', 535)]
Tamanho vocabulario bigramas: 830
Bigramas mais comuns [('taxa servico', 1445), ('codigo servico', 496), ('ser
vico importado', 496), ('importado impiss', 496), ('impiss xml', 463), ('hos
pedagem qualquer', 449), ('qualquer natureza', 449), ('natureza hoteis', 35
0), ('room tax', 277), ('contribuicao socio', 270)]
```

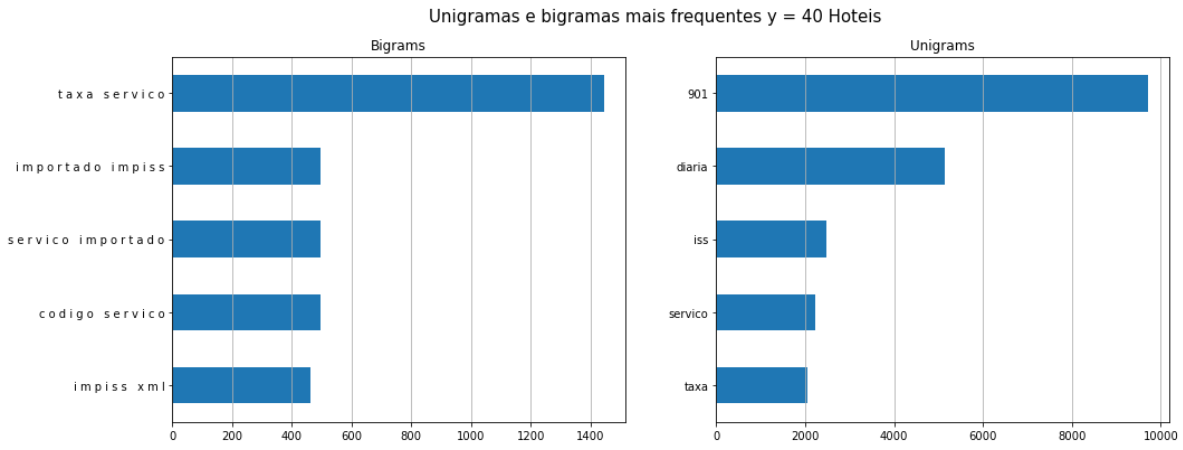

In [23]:

```
1 plot_uni_bigramas(60, 'Transporte rodoviario coletivo de passageiros')
```

```
Tamanho vocabulario unigramas: 430
Unigramas mais comuns: [('passageiros', 7764), ('dinheiro', 6788), ('1601',
3817), ('transporte', 3433), ('municipal', 1829), ('vale', 1826), ('escola
r', 1075), ('servicos', 902), ('venda', 875), ('web', 668)]
Tamanho vocabulario bigramas: 616
Bigramas mais comuns [('passageiros dinheiro', 6787), ('vale transporte', 15
22), ('transporte web', 639), ('transporte passageiros', 586), ('servicos tr
ansporte', 549), ('passageiros municipal', 455), ('transporte municipal', 45
1), ('receitas vendas', 449), ('vendas empresa', 440), ('natureza municipa
l', 409)]
```

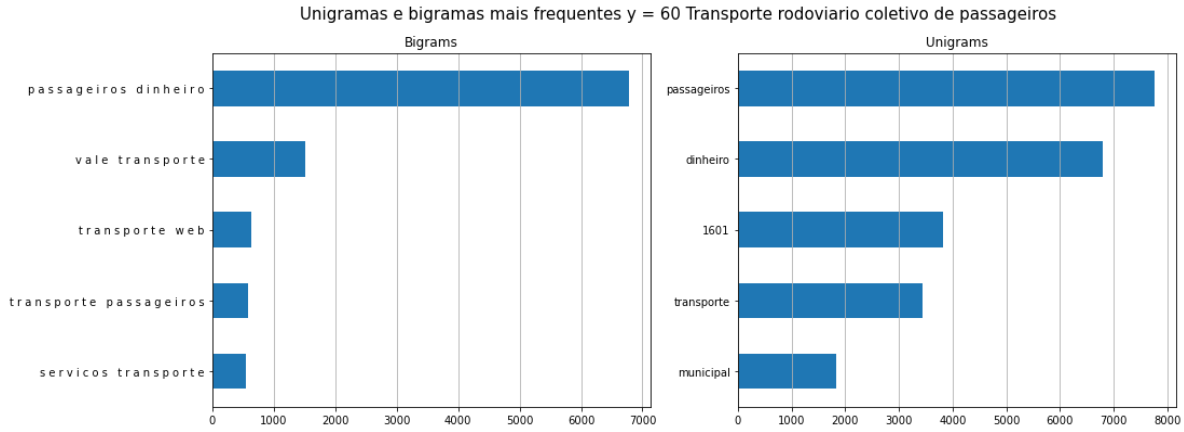

In [24]:

```
1 plot_uni_bigramas(70, 'Transporte aereo e maritimo')
```

```
Tamanho vocabulario unigramas: 607
Unigramas mais comuns: [('residuos', 6260), ('gerenciamento', 6252), ('709',
4814), ('servico', 3391), ('transporte', 3347), ('1601', 3252), ('prestado',
2940), ('armaz', 1243), ('claros', 1231), ('terc', 1171)]
Tamanho vocabulario bigramas: 970
Bigramas mais comuns [('gerenciamento residuos', 6240), ('servico prestado',
2940), ('prestado transporte', 2940), ('material diverso', 885), ('cgdg nt',
507), ('cg ct', 454), ('ct alcool', 453), ('ct biodiesel', 388), ('dg ct', 3
66), ('natureza municipal', 314)]
```

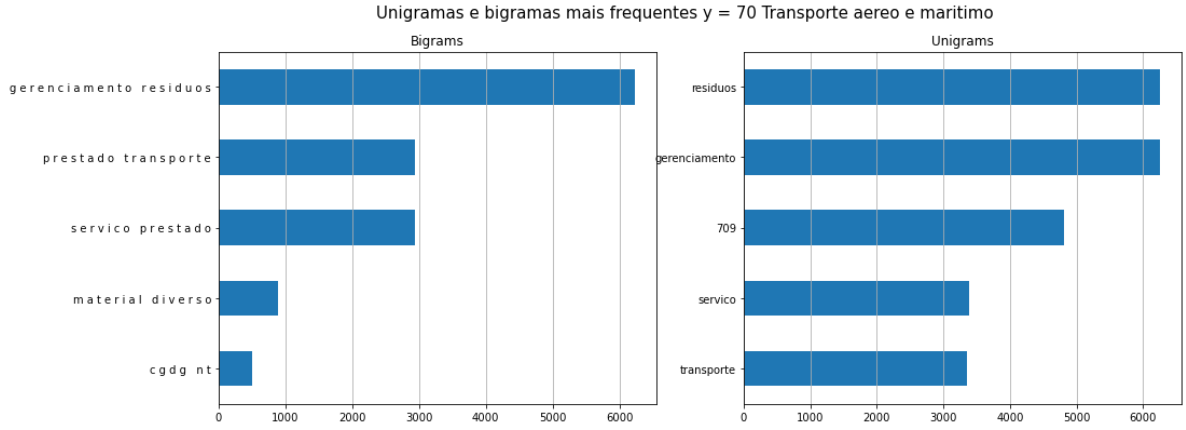

In [25]:

```
1 plot_uni_bigramas(71, 'Manutenção e reparação de aeronaves')
```

```
Tamanho vocabulario unigramas: 266
Unigramas mais comuns: [('maodeobra', 8075), ('1401', 7606), ('oficina', 521
7), ('hangar', 2838), ('manutencao', 2670), ('servico', 1934), ('conserto',
1669), ('restauracao', 1488), ('reparo', 1463), ('servicos', 1444)]
Tamanho vocabulario bigramas: 332
Bigramas mais comuns [('maodeobra oficina', 5217), ('maodeobra hangar', 219
3), ('conserto restauracao', 1485), ('manutencao conservacao', 1125), ('serv
ico geral', 1060), ('lubrificacao limpeza', 1039), ('contrato horas', 971),
('horas voo', 971), ('restauracao manutencao', 917), ('lustracao revisao', 6
59)]
```

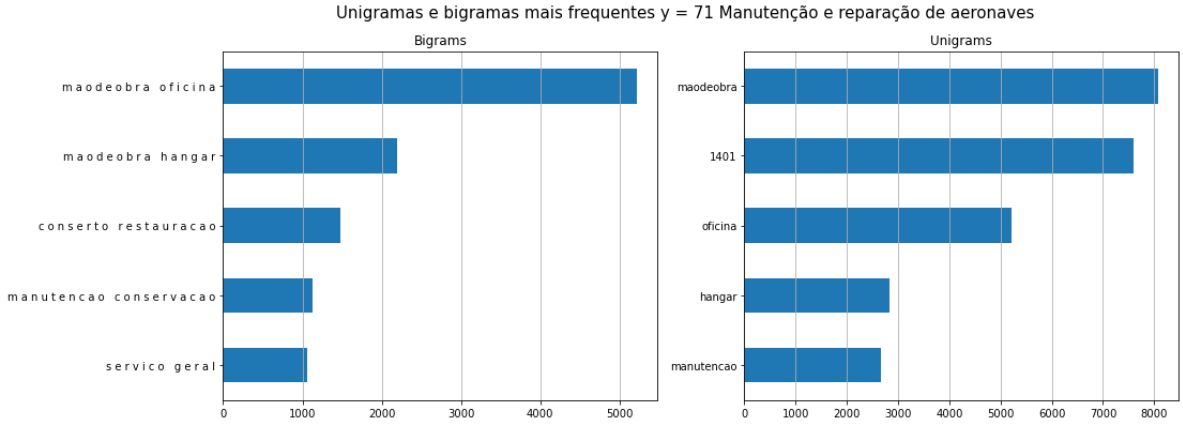

In [26]:

```
1 plot_uni_bigramas(72, 'Apoio maritimo e portuario')
```

```
Tamanho vocabulario unigramas: 433
Unigramas mais comuns: [('rebocagem', 6368), ('2001', 4862), ('portuario', 4
369), ('fiscal', 4093), ('sv', 4037), ('internacional', 3520), ('nacional',
2860), ('agencia', 2721), ('reboc', 2696), ('int', 2695)]
Tamanho vocabulario bigramas: 491
Bigramas mais comuns [('sv portuario', 4036), ('portuario fiscal', 4036),
('rebocagem internacional', 3520), ('rebocagem nacional', 2837), ('reboc in
t', 2695), ('int agencia', 2695), ('servicos portuarios', 677), ('utilizacao
porto', 579), ('portuarios ferroportuarios', 576), ('ferroportuarios utiliza
cao', 576)]
```

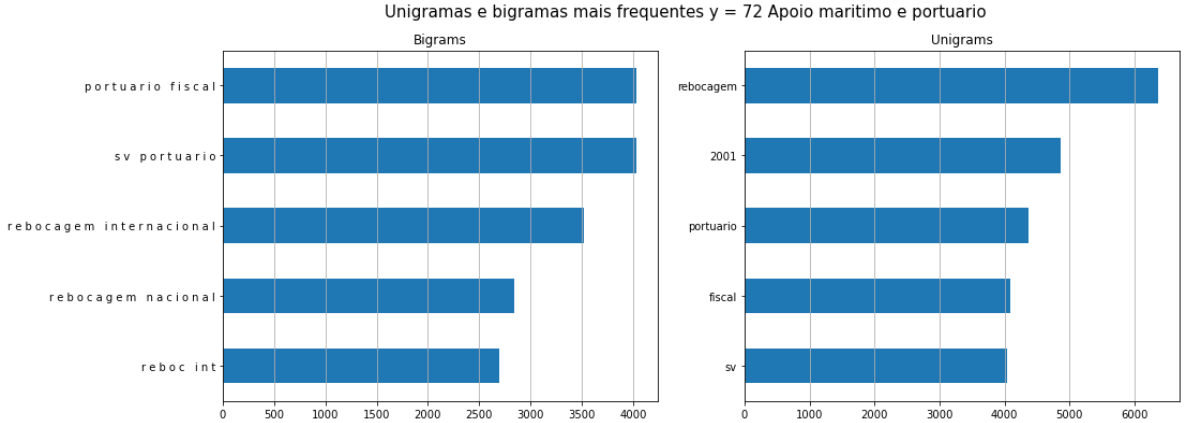

In [27]:

```
1 plot_uni_bigramas(80, 'Manutenção e reparação de embarcações')
```

```
Tamanho vocabulario unigramas: 386
Unigramas mais comuns: [('1401', 13459), ('locacao', 7824), ('vaga', 7820),
('servico', 3014), ('importado', 2878), ('impiss', 2878), ('codigo', 2875),
('xml', 2864), ('manutencao', 1856), ('equipamentos', 981)]
Tamanho vocabulario bigramas: 451
Bigramas mais comuns [('locacao vaga', 7820), ('importado impiss', 2878),
('codigo servico', 2875), ('servico importado', 2875), ('impiss xml', 2864),
('horario normal', 672), ('manutencao embarcacoes', 609), ('lubrificacao lim
peza', 599), ('limpeza lustracao', 599), ('lustracao revisao', 599)]
```

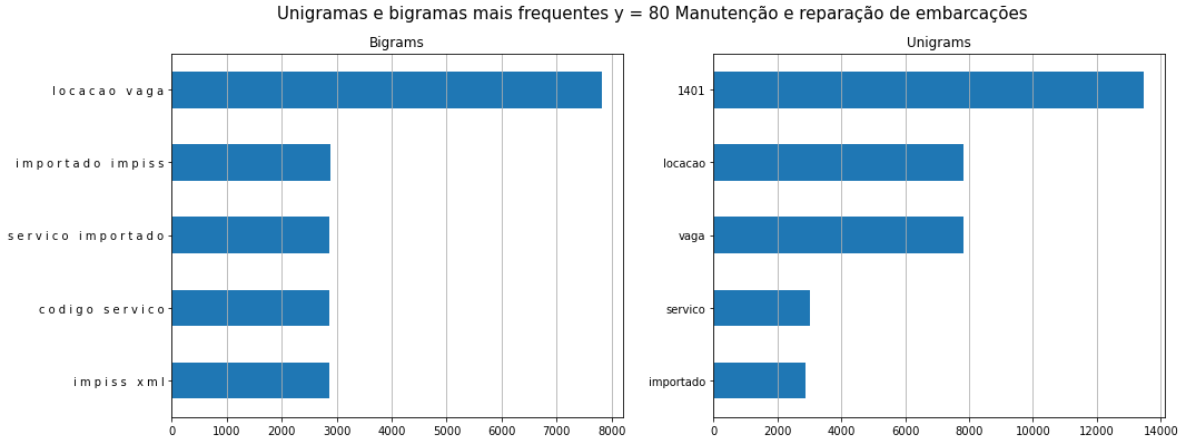

In [28]:

```
1 plot_uni_bigramas(90, 'Construção Civil')
```

```
Tamanho vocabulario unigramas: 2611
Unigramas mais comuns: [('servicos', 4442), ('702', 4153), ('servico', 307
2), ('manutencao', 2328), ('execucao', 2038), ('construcao', 1864), ('civi
l', 1836), ('empreitada', 1681), ('prestados', 1594), ('obras', 1526)]
Tamanho vocabulario bigramas: 4605
Bigramas mais comuns [('servicos prestados', 1558), ('construcao civil', 121
8), ('execucao administracao', 878), ('administracao empreitada', 821), ('se
rvico manutencao', 815), ('prestacao servicos', 759), ('manutencao elevadore
s', 695), ('mao obra', 690), ('empreitada subempreitada', 606), ('regime emp
reitada', 591)]
```

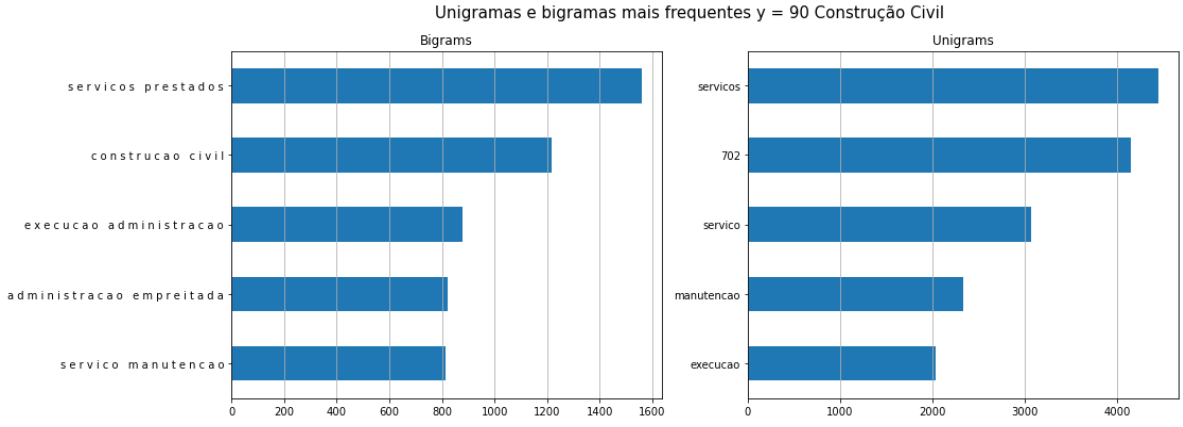

In [29]:

```
1 plot_uni_bigramas(120, 'Obras de infraestrutura')
```

```
Tamanho vocabulario unigramas: 1760
Unigramas mais comuns: [('702', 6635), ('servicos', 3872), ('servico', 330
5), ('empreitada', 2490), ('execucao', 1903), ('prestados', 1553), ('civil',
1342), ('3101', 1243), ('administracao', 1219), ('obra', 1166)]
Tamanho vocabulario bigramas: 2713
Bigramas mais comuns [('servicos prestados', 1462), ('administracao empreita
da', 1184), ('execucao administracao', 1164), ('servconstadeqrede optica', 9
06), ('optica regime', 906), ('regime empreitada', 906), ('obra civil', 70
4), ('servicos engenharia', 675), ('servico obra', 654), ('empreitada subemp
r', 647)]
```

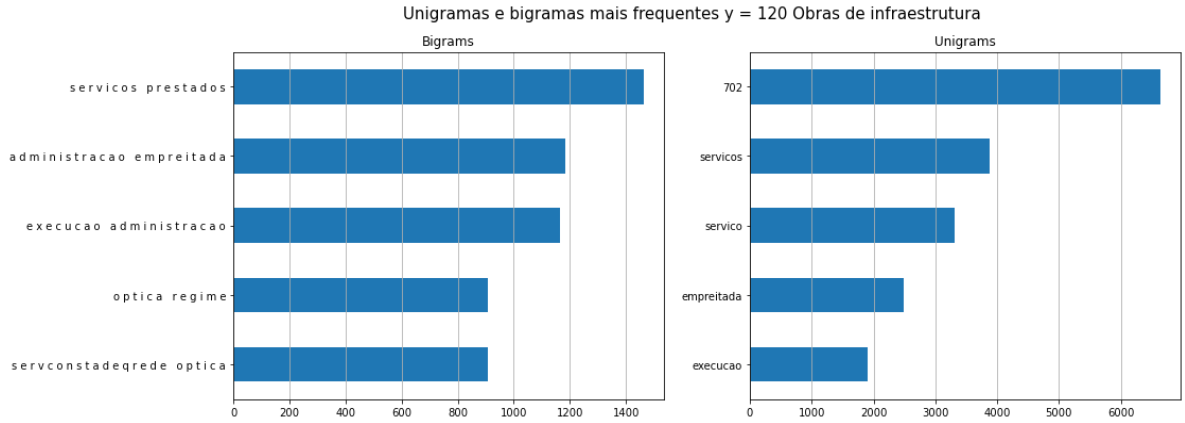

In [30]:

```
1 plot_uni_bigramas(130, 'Carga, descarga e armazenagem')
```

```
Tamanho vocabulario unigramas: 658
Unigramas mais comuns: [('2001', 5882), ('2002', 2329), ('sv', 2066), ('serv
ico', 2043), ('teca', 1898), ('importacoes', 1694), ('fiscal', 1524), ('arma
zenagem', 1461), ('lcl', 1417), ('portuario', 1287)]
Tamanho vocabulario bigramas: 935
Bigramas mais comuns [('servico teca', 1898), ('teca importacoes', 1694),
('sv portuario', 1282), ('portuario fiscal', 1282), ('servicos portuarios',
778), ('sv seg', 542), ('seg vigilan', 542), ('portuarios praticagem', 512),
('nao invasiva', 493), ('movimentacao mercadorias', 400)]
```

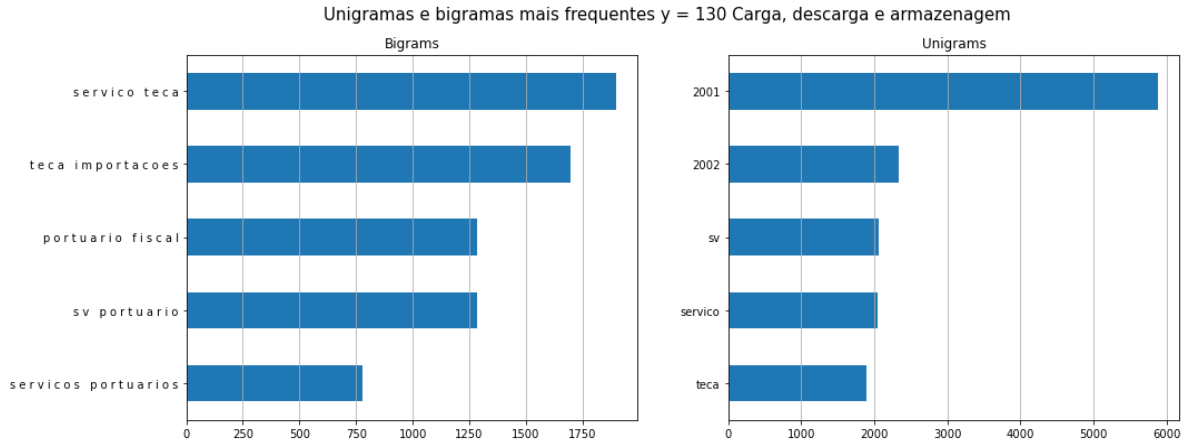

In [31]:

```
1 plot_uni_bigramas(140, 'Transporte rodoviario de cargas')
```

```
Tamanho vocabulario unigramas: 1207
Unigramas mais comuns: [('servicos', 5277), ('transporte', 4879), ('2001', 3
837), ('1601', 2778), ('municipal', 2008), ('servico', 1888), ('natureza', 1
559), ('1104', 915), ('armazenagem', 911), ('logistica', 848)]
Tamanho vocabulario bigramas: 1721
Bigramas mais comuns [('servicos transporte', 2149), ('transporte natureza',
1361), ('natureza municipal', 1359), ('servico transporte', 985), ('servicos
logistica', 828), ('servicos prestados', 521), ('handling importacao', 516),
('prestacao servicos', 478), ('armazenagem container', 411), ('container ip
a', 409)]
```

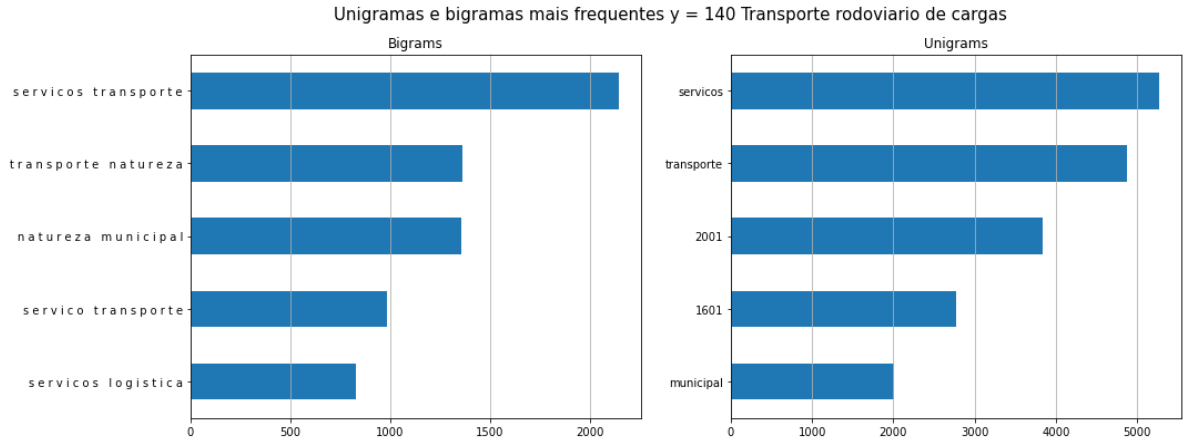

In [32]:

```
1 plot_uni_bigramas(200, 'Jornais, radios e TV')
```

```
Tamanho vocabulario unigramas: 1217
Unigramas mais comuns: [('iob', 1937), ('escritorio', 1926), ('servico', 170
9), ('sv', 1455), ('noticia', 1213), ('super', 1206), ('digital', 1202), ('a
ssinaturas', 1056), ('1706', 1011), ('anuncio', 964)]
Tamanho vocabulario bigramas: 1503
Bigramas mais comuns [('super noticia', 1205), ('noticia sv', 1204), ('assin
aturas digital', 1055), ('iob consultoria', 908), ('consultoria chat', 537),
('edicao integrada', 433), ('integrada impressao', 433), ('impressao jornai
s', 433), ('servico disponibilizacao', 354), ('disponibilizacao temporaria',
354)]
```

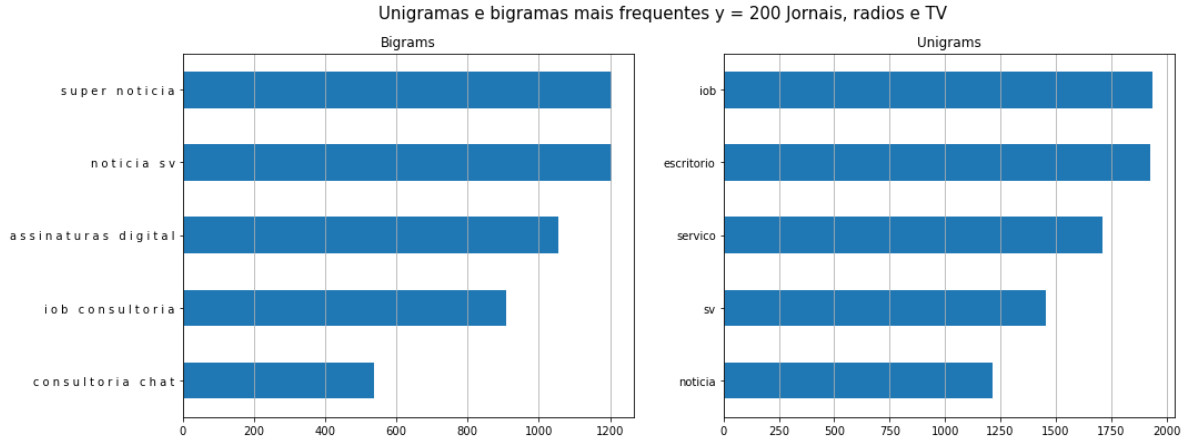

In [33]:

```
# call center
drop_index =  treino.loc[(treino.text_clean.str.contains('call center')) & (treino.y !=
treino = treino.drop(index = drop_index)
drop_index = treino.loc[(treino.text_clean.str.contains('cobranca')) & (treino.y != 30)
treino = treino.drop(index = drop_index)
```

In [34]:

```
# construcao_civil: empreitada, subempreitada, construcao
drop_index = treino.loc[(treino.text_clean.str.contains('empreitada')) & (~ treino.y.is
treino = treino.drop(index = drop_index)

drop_index = treino.loc[(treino.text_clean.str.contains('subempreitada')) & (~ treino.y
treino = treino.drop(index = drop_index)

drop_index = treino.loc[(treino.text_clean.str.contains('construcao')) & (~ treino.y.is
treino = treino.drop(index = drop_index)
```

In [35]:

```
# transporte e construcao_civil 999 (nao optantes)
# carga, descarga, armazenagem, portuario, praticagem, manutencao, obra, obras, engenha
drop_index = treino.loc[(treino.text_clean.str.contains('carga')) & (treino.y == 999)].
treino = treino.drop(index = drop_index)

drop_index = treino.loc[(treino.text_clean.str.contains('descarga')) & (treino.y == 999
treino = treino.drop(index = drop_index)

drop_index = treino.loc[(treino.text_clean.str.contains('armazenagem')) & (treino.y ==
treino = treino.drop(index = drop_index)

drop_index = treino.loc[(treino.text_clean.str.contains('portuario')) & (treino.y == 99
treino = treino.drop(index = drop_index)

drop_index = treino.loc[(treino.text_clean.str.contains('praticagem')) & (treino.y == 9
treino = treino.drop(index = drop_index)

drop_index = treino.loc[(treino.text_clean.str.contains('manutencao')) & (treino.y == 9
treino = treino.drop(index = drop_index)

drop_index = treino.loc[(treino.text_clean.str.contains('obra')) & (treino.y == 999)].i
treino = treino.drop(index = drop_index)

drop_index = treino.loc[(treino.text_clean.str.contains('obras')) & (treino.y == 999)].
treino = treino.drop(index = drop_index)

drop_index = treino.loc[(treino.text_clean.str.contains('engenharia')) & (treino.y == 9
treino = treino.drop(index = drop_index)

drop_index = treino.loc[(treino.text_clean.str.contains('transporte')) & (treino.y == 9
treino = treino.drop(index = drop_index)

drop_index = treino.loc[(treino.text_clean.str.contains('logistica')) & (treino.y == 99
treino = treino.drop(index = drop_index)
```

In [36]:

```
# excluindo da analise linhas com text_clean = ''
treino.loc[treino.text_clean == '', ['text_clean']] = 'servico'

# retirar linhas com y<>999 E text_clean: 'prestacao servico','servico','servicos','ser
treino = drop_dfindex(treino, treino.loc[(treino.y != 999) & (treino.text_clean == 'pre
treino = drop_dfindex(treino, treino.loc[(treino.y != 999) & (treino.text_clean == 'ser
treino = drop_dfindex(treino, treino.loc[(treino.y != 999) & (treino.text_clean == 'ser
treino = drop_dfindex(treino, treino.loc[(treino.y != 999) & (treino.text_clean == 'ser

# linhas (cada linha com 1 documento) para composicao de vetores com unigramas
docs_train = treino.text_clean.values  # unigramas
ytrain = treino.y.values
```

In [37]:

```
def plot_distribuicao_classe(df, x, y):
    palette = sns.husl_palette(df[y].nunique())
    fig, (ax1, ax2) = plt.subplots(nrows=1, ncols=2, figsize=(16,6))
    fig.suptitle(x, fontsize=12)
    for nr,cat in enumerate(df[y].unique()):
        sns.kdeplot(data= df[df[y]==cat], x=x,
                    cbar_kws={"alpha":0.8}, color=palette[nr], shade=True, ax=ax1)
        sns.histplot(data= df[df[y]==cat], x=x,
                    bins=10, cbar_kws={"alpha":0.8}, color=palette[nr], ax=ax2)
    ax1.grid(True)
    ax2.grid(True)
    ax1.legend(df[y].unique())
    ax2.legend(df[y].unique())
```

In [38]:

```
# distribuicao da soma de caracteres por documento
treino['char_count'] = treino["text_clean"].apply(lambda x: sum(len(word) for word in s
plot_distribuicao_classe(treino, 'char_count', 'y')
```

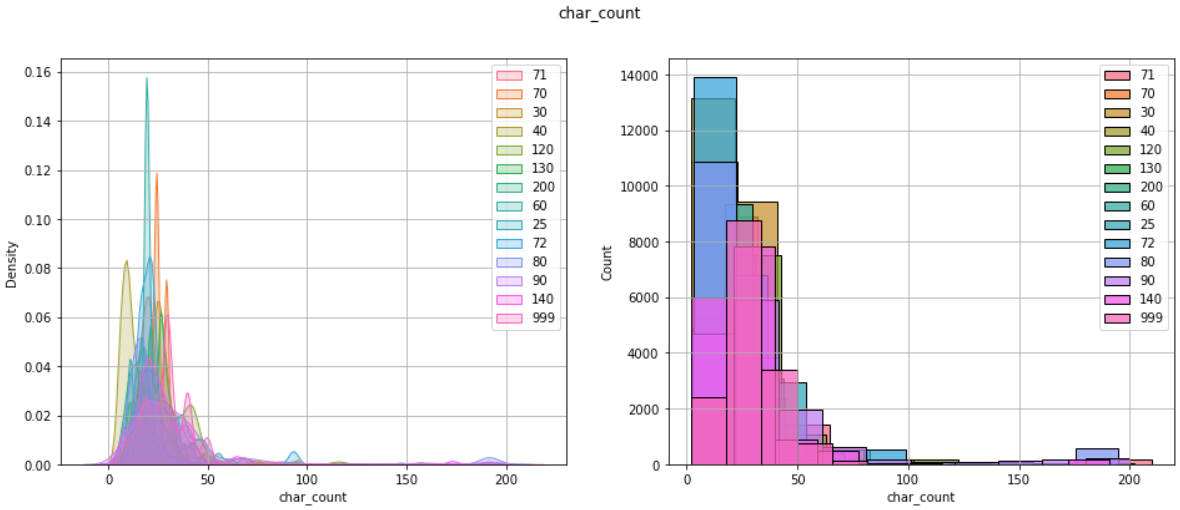

In [39]:

```
# distribuicao da contagem de palavras por documento
treino['word_count'] = treino["text_clean"].apply(lambda x: len(str(x).split(" ")))  #
plot_distribuicao_classe(treino, 'word_count', 'y')
```

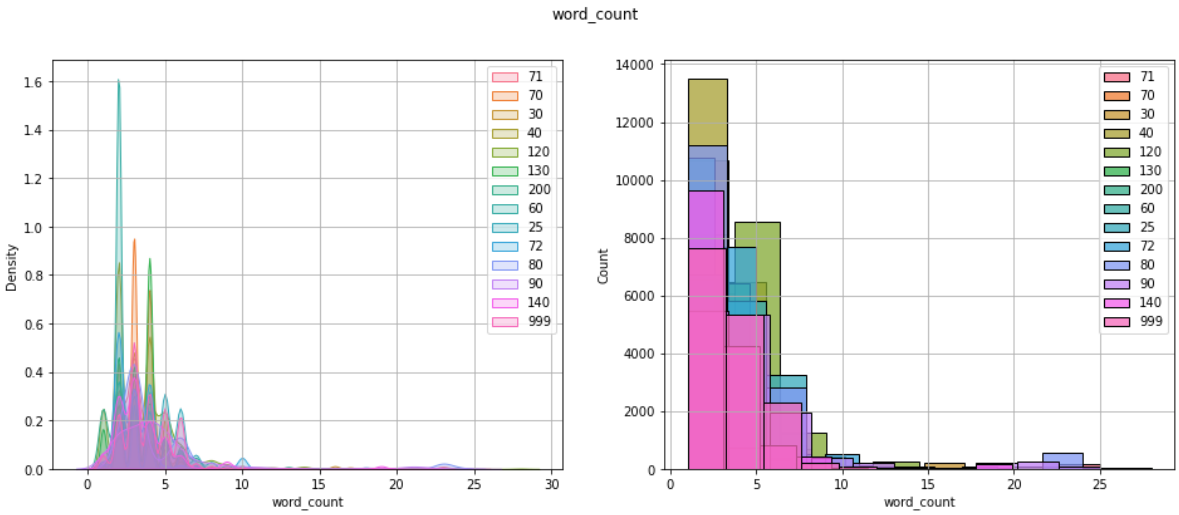

In [40]:

```
# DataSet de validação
path = r'../data/dataset_ML_val.parq'
val = pd.read_parquet(path, engine='auto')

# unigramas com limpeza do texto no DataSet de validação
val['text_clean'] = val[['cd_lc','text']].apply(doc_to_line, axis=1)
val.loc[val.text_clean == '', ['text_clean']] = 'servico'          # classe 999 quando l

docs_val = val.text_clean.values
yval = val.y.values

print(val.shape)
val.y.value_counts().sort_values().plot(kind='barh', legend=False).grid(axis='x');
```

```
(14000, 4)
```

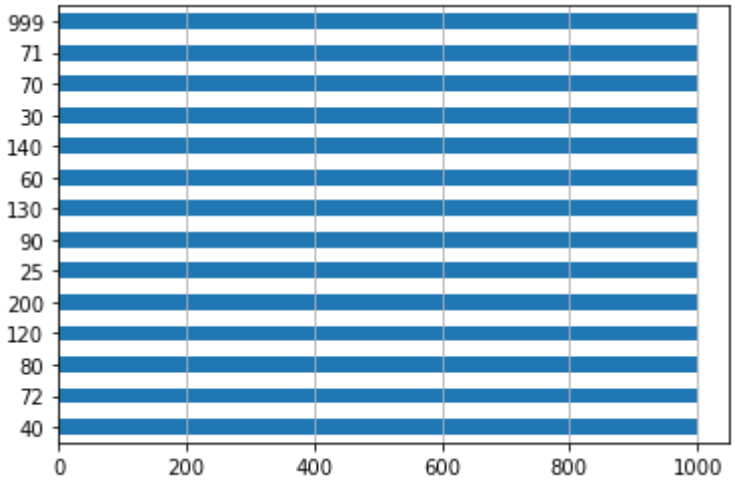

Comparando resultados na vetorização dos documentos:

- binary = palavras são marcadas como presentes (1) ou ausentes (0)
- count = contagem de ocorrências de cada palavra como um número inteiro
- freq = frequência de cada palavra no documento
- tfidf = frequência das palavras com penalização das palavras mais comuns (frequência + grau de raridade)
- hash = frequência das palavras com limitação das features (colunas) na matriz de vetores

In [41]:

```
# unigramas
binary_vectorizer = CountVectorizer(binary=True)
count_vectorizer = CountVectorizer()
freq_vectorizer = TfidfVectorizer(use_idf=False)
tfidf_vectorizer = TfidfVectorizer()
hashing_vectorizer = HashingVectorizer(n_features = 2 ** 11)

# bigramas
binary_vectorizer2 = CountVectorizer(binary=True, ngram_range=(1,2))
count_vectorizer2 = CountVectorizer(ngram_range=(1,2))
freq_vectorizer2 = TfidfVectorizer(use_idf=False, ngram_range=(1,2))
tfidf_vectorizer2 = TfidfVectorizer(ngram_range=(1,2))
hashing_vectorizer2 = HashingVectorizer(n_features = 2 ** 11, ngram_range=(1,2))
```

In [42]:

```
# teste chi2 para seleção de features relevantes com unigramas
Xtrain_names_binary = teste_chi2(docs=docs_train, y=ytrain, vectorizer = binary_vectori
binary_vectorizer_chi2 = CountVectorizer(binary=True, vocabulary = Xtrain_names_binary)
```

```
tamanho_vocabulario =  6315
(215298, 6315)
           feature  score    y
2869      graduacao 1.0000   80
2612           flat 0.9997   70
808         backbone 0.9873  130
5720           talao 0.9874   40
6047         unisys 1.0000   90
4565      portuario 1.0000  200
1580  contabilidade 0.9874  140
4913    reaventrega 1.0000  120
2220  encomnperiodo 0.9908   80
710           assist 1.0000   40

[10 rows x 3 columns]
vocab_testado: 6301
```

In [43]:

```
Xtrain_names_count = teste_chi2(docs=docs_train, y=ytrain, vectorizer = count_vectorize
count_vectorizer_chi2 = CountVectorizer(vocabulary = Xtrain_names_count)
```

```
tamanho_vocabulario =  6315
(215298, 6315)
           feature  score    y
5168           rio 0.9713  140
4203         outras 1.0000   71
1466       concreta 1.0000   90
1288  civileletrica 1.0000   90
5834       terminal 1.0000  140
1079         campos 0.9599  999
5609            stc 1.0000  120
653     armazenagem 1.0000  200
5781            tef 0.9820   72
4488     plataforma 1.0000   70

[10 rows x 3 columns]
vocab_testado: 6301
```

In [44]:

```
Xtrain_names_freq = teste_chi2(docs=docs_train, y=ytrain, vectorizer = freq_vectorizer)
freq_vectorizer_chi2 = TfidfVectorizer(use_idf=False, vocabulary = Xtrain_names_freq)
```

```
tamanho_vocabulario =  6315
(215298, 6315)
               feature  score    y
1128       carregamento 0.9996  200
3075                imp 0.9809  200
4354                ped 1.0000   90
5745          taxdoacao 0.9597   71
1069           cambagem 1.0000  999
4422          petrolina 1.0000  999
1129  carregamentosaida 1.0000   80
4225             pacote 1.0000  200
1978       distribuicao 0.9998   72
962          bookingcom 1.0000   40

[10 rows x 3 columns]
vocab_testado: 6175
```

In [45]:

```
Xtrain_names_tfidf = teste_chi2(docs=docs_train, y=ytrain, vectorizer = tfidf_vectorize
tfidf_vectorizer_chi2 = TfidfVectorizer(use_idf=True, vocabulary = Xtrain_names_tfidf)
```

```
tamanho_vocabulario =  6315
(215298, 6315)
            feature  score    y
5000     refrigerada 1.0000  130
428      agenciaepcm 1.0000  200
4439         picking 1.0000  130
4013              nh 0.9556   60
1724   cursogenerico 1.0000  200
1038       cabotagem 0.9925   71
3444             lgt 1.0000   30
326   acompanhamento 0.9981   60
5138          retido 1.0000  120
3658        maritimo 0.9885  120

[10 rows x 3 columns]
vocab_testado: 6247
```

In [46]:

```
# teste chi2 para seleção de features relevantes com unigramas e bigramas
Xtrain_names_binary2 = teste_chi2(docs=docs_train, y=ytrain, vectorizer = binary_vector
binary_vectorizer2_chi2 = CountVectorizer(binary=True, vocabulary = Xtrain_names_binary
```

```
tamanho_vocabulario =  26580
(215298, 26580)
                    feature  score    y
21699          sapata freio 1.0000   90
22267  servico balanceamento 0.9997  999
11147                   fed 0.9878  130
22632              servicos 1.0000  140
14657   locsupgespam compras 0.9997   25
20407               redacao 0.9929   25
16959            obra ferro 1.0000   90
3493         aeronaves parte 0.9996  130
19804         psubst roldana 0.9997   80
18225             permanente 0.9694  130

[10 rows x 3 columns]
vocab_testado: 26553
```

In [47]:

```
Xtrain_names_count2 = teste_chi2(docs=docs_train, y=ytrain, vectorizer = count_vectoriz
count_vectorizer2_chi2 = CountVectorizer(vocabulary = Xtrain_names_count2)
```

```
tamanho_vocabulario =  26580
(215298, 26580)
                           feature  score    y
17070                   obras frs 1.0000   90
24332                taxa servico 1.0000   25
14759                lubrificacao 1.0000   71
15179           manutencao sistemas 0.9776  999
22052                 serv emendas 0.9767   71
3919                  analise area 0.9997  999
1145                    1401 manut 0.9756   71
16524                nao perigosos 1.0000   70
16573            natureza servicos 0.9995   70
13185  infraestrutura administrativa 0.9851  140

[10 rows x 3 columns]
vocab_testado: 26553
```

In [48]:

```
Xtrain_names_freq2 = teste_chi2(docs=docs_train, y=ytrain, vectorizer = freq_vectorizer
freq_vectorizer2_chi2 = TfidfVectorizer(use_idf=False, vocabulary = Xtrain_names_freq2)
```

```
tamanho_vocabulario =  26580
(215298, 26580)
                     feature  score    y
17260                   oper 0.9893   25
1929              2002 ataero 0.9998   90
26181                versoes 0.9953   25
2687              705 servicos 0.9505   71
6073                   cartao 0.9984   90
4944               autorizacao 1.0000  200
4790             ato cooperado 1.0000  999
25373  treinamento orientacao 1.0000  999
13526            intermediacao 1.0000  130
9418             ecomp aracruz 1.0000   70

[10 rows x 3 columns]
vocab_testado: 24243
```

In [49]:

```
Xtrain_names_tfidf2 = teste_chi2(docs=docs_train, y=ytrain, vectorizer = tfidf_vectoriz
tfidf_vectorizer2_chi2 = TfidfVectorizer(use_idf=True, vocabulary = Xtrain_names_tfidf2
```

```
tamanho_vocabulario =  26580
(215298, 26580)
                feature  score    y
25906  vale transportes 0.9999   60
24399         tec gaspaj 0.9993   70
19313      prestados703 0.9999   90
12691              hotel 0.9959   72
566         106 programa 1.0000  999
25878               vaga 1.0000   60
7430          congeneres 0.9997  200
15623    mensagem natal 0.9980  200
14538       lmi6114 rec 0.9996   72
20452   redes districao 0.9896   90

[10 rows x 3 columns]
vocab_testado: 25240
```

In [50]:

```
results_ml = pd.DataFrame(columns = ['acc','precision_macro','recall_macro','f1_macro',
def s_results(docs_train, ytrain, vectorizer=None, model=None, svd=None, docs_val=None,
    if svd:
        pipe = Pipeline(steps=[('vectorizer', vectorizer),
                               ('svd', TruncatedSVD(n_components=100, n_iter=10, randor
                               ('model', model)])
    else:
        pipe = Pipeline(steps=[('vectorizer', vectorizer),
                               ('model', model)])
    pipe.fit(docs_train, ytrain)
    yv_pred = pipe.predict(docs_val)
    acc = accuracy_score(yval, yv_pred)
    p_m = precision_score(yval, yv_pred, average='macro')
    r_m = recall_score(yval, yv_pred, average='macro')
    f1_m = f1_score(yval, yv_pred, average='macro')
    mcc = matthews_corrcoef(yval, yv_pred)
    return pd.Series(data=[acc, p_m, r_m, f1_m, mcc], index=['acc','precision_macro','r
```

ML teste de algorítimos

legenda utilizada:

- NB: Naive Bayes MultinomialNB
- RF: Random Forest
- LG: Regressão Logística
- SVM: Suport Vector Machines
- uni: unigragmas
- bi: bigramas
- chi2: redução de features pelo método chi_quadrado
- SVD: redução de features pelo método SVD

Naive Bayes MultinomialNB

- parâmetro padrão: alpha = 1.0

In [51]:

```
# binary
results_ml.loc['NB_binary_uni'] = s_results(docs_train, ytrain, vectorizer= binary_vect
                                  model= MultinomialNB(), docs_val=docs_val, yval=yv

results_ml.loc['NB_binary_uni_chi2'] = s_results(docs_train, ytrain, vectorizer= binary
                                  model= MultinomialNB(), docs_val=docs_val, yval=yv

results_ml.loc['NB_binary_bi'] = s_results(docs_train, ytrain, vectorizer= binary_vecto
                                  model= MultinomialNB(), docs_val=docs_val, yval=yv

results_ml.loc['NB_binary_bi_chi2'] = s_results(docs_train, ytrain, vectorizer= binary_
                                  model= MultinomialNB(), docs_val=docs_val, yval=yv
```

In [52]:

```
# count
results_ml.loc['NB_count_uni'] = s_results(docs_train, ytrain, vectorizer= count_vector
                                    model= MultinomialNB(), docs_val=docs_val, yval=yv

results_ml.loc['NB_count_uni_chi2'] = s_results(docs_train, ytrain, vectorizer= count_v
                                    model= MultinomialNB(), docs_val=docs_val, yval=yv

results_ml.loc['NB_count_bi'] = s_results(docs_train, ytrain, vectorizer= count_vectori
                                    model= MultinomialNB(), docs_val=docs_val, yval=yv

results_ml.loc['NB_count_bi_chi2'] = s_results(docs_train, ytrain, vectorizer= count_ve
                                    model= MultinomialNB(), docs_val=docs_val, yval=yv
```

In [53]:

```
# freq
results_ml.loc['NB_freq_uni'] = s_results(docs_train, ytrain, vectorizer= freq_vectoriz
                                    model= MultinomialNB(), docs_val=docs_val, yval=yv

results_ml.loc['NB_freq_uni_chi2'] = s_results(docs_train, ytrain, vectorizer= freq_vec
                                    model= MultinomialNB(), docs_val=docs_val, yval=yv

results_ml.loc['NB_freq_bi'] = s_results(docs_train, ytrain, vectorizer= freq_vectorize
                                    model= MultinomialNB(), docs_val=docs_val, yval=yv

results_ml.loc['NB_freq_bi_chi2'] = s_results(docs_train, ytrain, vectorizer= freq_vect
                                    model= MultinomialNB(), docs_val=docs_val, yval=yv
```

In [54]:

```
# tfidf
results_ml.loc['NB_tfidf_uni'] = s_results(docs_train, ytrain, vectorizer= tfidf_vector
                                    model= MultinomialNB(), docs_val=docs_val, yval=yv

results_ml.loc['NB_tfidf_uni_chi2'] = s_results(docs_train, ytrain, vectorizer= tfidf_v
                                    model= MultinomialNB(), docs_val=docs_val, yval=yv

results_ml.loc['NB_tfidf_bi'] = s_results(docs_train, ytrain, vectorizer= tfidf_vectori
                                    model= MultinomialNB(), docs_val=docs_val, yval=yv

results_ml.loc['NB_tfidf_bi_chi2'] = s_results(docs_train, ytrain, vectorizer= tfidf_ve
                                    model= MultinomialNB(), docs_val=docs_val, yval=yv
```

Regressão Logística

In [55]:

```
# binary
results_ml.loc['LG_binary_uni'] = s_results(docs_train, ytrain, vectorizer= binary_vect
                                    model= LogisticRegression(solver='liblinear', rand

results_ml.loc['LG_binary_uni_SVD'] = s_results(docs_train, ytrain, vectorizer= binary_
                                           svd=True,
                                    model= LogisticRegression(solver='liblinear', rand

results_ml.loc['LG_binary_uni_chi2'] = s_results(docs_train, ytrain, vectorizer= binary
                                    model= LogisticRegression(solver='liblinear', rand

results_ml.loc['LG_binary_bi'] = s_results(docs_train, ytrain, vectorizer= binary_vecto
                                    model= LogisticRegression(solver='liblinear', rand

results_ml.loc['LG_binary_bi_SVD'] = s_results(docs_train, ytrain, vectorizer= binary_v
                                          svd=True,
                                    model= LogisticRegression(solver='liblinear', rand

results_ml.loc['LG_binary_bi_chi2'] = s_results(docs_train, ytrain, vectorizer= binary_
                                    model= LogisticRegression(solver='liblinear', rand
```

In [56]:

```
# count
results_ml.loc['LG_count_uni'] = s_results(docs_train, ytrain, vectorizer= count_vector
                                    model= LogisticRegression(solver='liblinear', rand

results_ml.loc['LG_count_uni_SVD'] = s_results(docs_train, ytrain, vectorizer= count_ve
                                    svd=True,
                                    model= LogisticRegression(solver='liblinear', rand

results_ml.loc['LG_count_uni_chi2'] = s_results(docs_train, ytrain, vectorizer= count_v
                                    model= LogisticRegression(solver='liblinear', rand

results_ml.loc['LG_count_bi'] = s_results(docs_train, ytrain, vectorizer= count_vectori
                                    model= LogisticRegression(solver='liblinear', rand

results_ml.loc['LG_count_bi_SVD'] = s_results(docs_train, ytrain, vectorizer= count_vec
                                          svd=True,
                                    model= LogisticRegression(solver='liblinear', rand

results_ml.loc['LG_count_bi_chi2'] = s_results(docs_train, ytrain, vectorizer= count_ve
                                    model= LogisticRegression(solver='liblinear', rand
```

In [57]:

```
# freq
results_ml.loc['LG_freq_uni'] = s_results(docs_train, ytrain, vectorizer= freq_vectoriz
                                          model= LogisticRegression(solver='liblinear', rand

results_ml.loc['LG_freq_uni_SVD'] = s_results(docs_train, ytrain, vectorizer= freq_vect
                                              svd=True,
                                          model= LogisticRegression(solver='liblinear', rand

results_ml.loc['LG_freq_uni_chi2'] = s_results(docs_train, ytrain, vectorizer= freq_vec
                                          model= LogisticRegression(solver='liblinear', rand

results_ml.loc['LG_freq_bi'] = s_results(docs_train, ytrain, vectorizer= freq_vectorize
                                          model= LogisticRegression(solver='liblinear', rand

results_ml.loc['LG_freq_bi_SVD'] = s_results(docs_train, ytrain, vectorizer= freq_vecto
                                             svd=True,
                                          model= LogisticRegression(solver='liblinear', rand

results_ml.loc['LG_freq_bi_chi2'] = s_results(docs_train, ytrain, vectorizer= freq_vect
                                          model= LogisticRegression(solver='liblinear', rand
```

In [58]:

```
# tfidf
results_ml.loc['LG_tfidf_uni'] = s_results(docs_train, ytrain, vectorizer= tfidf_vector
                                          model= LogisticRegression(solver='liblinear', rand

results_ml.loc['LG_tfidf_uni_SVD'] = s_results(docs_train, ytrain, vectorizer= tfidf_ve
                                           svd=True,
                                          model= LogisticRegression(solver='liblinear', rand

results_ml.loc['LG_tfidf_uni_chi2'] = s_results(docs_train, ytrain, vectorizer= tfidf_v
                                          model= LogisticRegression(solver='liblinear', rand

results_ml.loc['LG_tfidf_bi'] = s_results(docs_train, ytrain, vectorizer= tfidf_vectori
                                          model= LogisticRegression(solver='liblinear', rand

results_ml.loc['LG_tfidf_bi_SVD'] = s_results(docs_train, ytrain, vectorizer= tfidf_vec
                                              svd=True,
                                          model= LogisticRegression(solver='liblinear', rand

results_ml.loc['LG_tfidf_bi_chi2'] = s_results(docs_train, ytrain, vectorizer= tfidf_ve
                                          model= LogisticRegression(solver='liblinear', rand
```

In [59]:

```
# hash
results_ml.loc['LG_hash_uni'] = s_results(docs_train, ytrain, vectorizer= hashing_vecto
                                    model= LogisticRegression(solver='liblinear', rand

results_ml.loc['LG_hash_uni_SVD'] = s_results(docs_train, ytrain, vectorizer= hashing_v
                                        svd=True,
                                    model= LogisticRegression(solver='liblinear', rand

results_ml.loc['LG_hash_bi'] = s_results(docs_train, ytrain, vectorizer= hashing_vector
                                    model= LogisticRegression(solver='liblinear', rand

results_ml.loc['LG_hash_bi_SVD'] = s_results(docs_train, ytrain, vectorizer= hashing_ve
                                       svd=True,
                                    model= LogisticRegression(solver='liblinear', rand
```

SVM: Support Vector Machines

parâmetro padrão: kernel rbf, C = 1.0, gamma = scale

In [60]:

```
# binary
results_ml.loc['SVM_binary_uni'] = s_results(docs_train, ytrain, vectorizer= binary_vec
                                    model= SVC(random_state=0), docs_val=docs_val, yva

results_ml.loc['SVM_binary_uni_SVD'] = s_results(docs_train, ytrain, vectorizer= binary
                                    svd=True,
                                    model= SVC(random_state=0), docs_val=docs_val, yva

results_ml.loc['SVM_binary_uni_chi2'] = s_results(docs_train, ytrain, vectorizer= binar
                                    model= SVC(random_state=0), docs_val=docs_val, yva

results_ml.loc['SVM_binary_bi'] = s_results(docs_train, ytrain, vectorizer= binary_vect
                                    model= SVC(random_state=0), docs_val=docs_val, yva

results_ml.loc['SVM_binary_bi_SVD'] = s_results(docs_train, ytrain, vectorizer= binary_
                                    svd=True,
                                    model= SVC(random_state=0), docs_val=docs_val, yva

results_ml.loc['SVM_binary_bi_chi2'] = s_results(docs_train, ytrain, vectorizer= binary
                                    model= SVC(random_state=0), docs_val=docs_val, yva
```

In [61]:

```
# count
results_ml.loc['SVM_count_uni'] = s_results(docs_train, ytrain, vectorizer= count_vecto
                                    model= SVC(random_state=0), docs_val=docs_val, yva

results_ml.loc['SVM_count_uni_SVD'] = s_results(docs_train, ytrain, vectorizer= count_v
                                    svd=True,
                                    model= SVC(random_state=0), docs_val=docs_val, yva

results_ml.loc['SVM_count_uni_chi2'] = s_results(docs_train, ytrain, vectorizer= count_
                                    model= SVC(random_state=0), docs_val=docs_val, yva

results_ml.loc['SVM_count_bi'] = s_results(docs_train, ytrain, vectorizer= count_vector
                                    model= SVC(random_state=0), docs_val=docs_val, yva

results_ml.loc['SVM_count_bi_SVD'] = s_results(docs_train, ytrain, vectorizer= count_ve
                                        svd=True,
                                    model= SVC(random_state=0), docs_val=docs_val, yva

results_ml.loc['SVM_count_bi_chi2'] = s_results(docs_train, ytrain, vectorizer= count_v
                                    model= SVC(random_state=0), docs_val=docs_val, yva
```

In [62]:

```
# freq
results_ml.loc['SVM_freq_uni'] = s_results(docs_train, ytrain, vectorizer= freq_vectori
                                    model= SVC(random_state=0), docs_val=docs_val, yva

results_ml.loc['SVM_freq_uni_SVD'] = s_results(docs_train, ytrain, vectorizer= freq_vec
                                        svd=True,
                                    model= SVC(random_state=0), docs_val=docs_val, yva

results_ml.loc['SVM_freq_uni_chi2'] = s_results(docs_train, ytrain, vectorizer= freq_ve
                                    model= SVC(random_state=0), docs_val=docs_val, yva

results_ml.loc['SVM_freq_bi'] = s_results(docs_train, ytrain, vectorizer= freq_vectoriz
                                    model= SVC(random_state=0), docs_val=docs_val, yva

results_ml.loc['SVM_freq_bi_SVD'] = s_results(docs_train, ytrain, vectorizer= freq_vect
                                      svd=True,
                                    model= SVC(random_state=0), docs_val=docs_val, yva

results_ml.loc['SVM_freq_bi_chi2'] = s_results(docs_train, ytrain, vectorizer= freq_vec
                                    model= SVC(random_state=0), docs_val=docs_val, yva
```

In [63]:

```
# tfidf
results_ml.loc['SVM_tfidf_uni'] = s_results(docs_train, ytrain, vectorizer= tfidf_vecto
                                    model= SVC(random_state=0), docs_val=docs_val, yva

results_ml.loc['SVM_tfidf_uni_SVD'] = s_results(docs_train, ytrain, vectorizer= tfidf_v
                                        svd=True,
                                    model= SVC(random_state=0), docs_val=docs_val, yva

results_ml.loc['SVM_tfidf_uni_chi2'] = s_results(docs_train, ytrain, vectorizer= tfidf_
                                    model= SVC(random_state=0), docs_val=docs_val, yva

results_ml.loc['SVM_tfidf_bi'] = s_results(docs_train, ytrain, vectorizer= tfidf_vector
                                    model= SVC(random_state=0), docs_val=docs_val, yva

results_ml.loc['SVM_tfidf_bi_SVD'] = s_results(docs_train, ytrain, vectorizer= tfidf_ve
                                       svd=True,
                                    model= SVC(random_state=0), docs_val=docs_val, yva

results_ml.loc['SVM_tfidf_bi_chi2'] = s_results(docs_train, ytrain, vectorizer= tfidf_v
                                    model= SVC(random_state=0), docs_val=docs_val, yva
```

In [64]:

```
# hash
results_ml.loc['SVM_hash_uni'] = s_results(docs_train, ytrain, vectorizer= hashing_vect
                                    model= SVC(random_state=0), docs_val=docs_val, yva

results_ml.loc['SVM_hash_uni_SVD'] = s_results(docs_train, ytrain, vectorizer= hashing_
                                       svd=True,
                                    model= SVC(random_state=0), docs_val=docs_val, yva

results_ml.loc['SVM_hash_bi'] = s_results(docs_train, ytrain, vectorizer= hashing_vecto
                                    model= SVC(random_state=0), docs_val=docs_val, yva

results_ml.loc['SVM_hash_bi_SVD'] = s_results(docs_train, ytrain, vectorizer= hashing_v
                                      svd=True,
                                    model= SVC(random_state=0), docs_val=docs_val, yva
```

Random Forest

In [65]:

```
# binary
results_ml.loc['RF_binary_uni'] = s_results(docs_train, ytrain, vectorizer= binary_vect
                                    model= RandomForestClassifier(random_state=0), doc

results_ml.loc['RF_binary_uni_SVD'] = s_results(docs_train, ytrain, vectorizer= binary_
                                        svd=True,
                                    model= RandomForestClassifier(random_state=0), doc

results_ml.loc['RF_binary_uni_chi2'] = s_results(docs_train, ytrain, vectorizer= binary
                                    model= RandomForestClassifier(random_state=0), doc

results_ml.loc['RF_binary_bi'] = s_results(docs_train, ytrain, vectorizer= binary_vecto
                                    model= RandomForestClassifier(random_state=0), doc

results_ml.loc['RF_binary_bi_SVD'] = s_results(docs_train, ytrain, vectorizer= binary_v
                                       svd=True,
                                    model= RandomForestClassifier(random_state=0), doc

results_ml.loc['RF_binary_bi_chi2'] = s_results(docs_train, ytrain, vectorizer= binary_
                                    model= RandomForestClassifier(random_state=0), doc
```

In [66]:

```
# count
results_ml.loc['RF_count_uni'] = s_results(docs_train, ytrain, vectorizer= count_vector
                                    model= RandomForestClassifier(random_state=0), doc

results_ml.loc['RF_count_uni_SVD'] = s_results(docs_train, ytrain, vectorizer= count_ve
                                       svd=True,
                                    model= RandomForestClassifier(random_state=0), doc

results_ml.loc['RF_count_uni_chi2'] = s_results(docs_train, ytrain, vectorizer= count_v
                                    model= RandomForestClassifier(random_state=0), doc

results_ml.loc['RF_count_bi'] = s_results(docs_train, ytrain, vectorizer= count_vectori
                                    model= RandomForestClassifier(random_state=0), doc

results_ml.loc['RF_count_bi_SVD'] = s_results(docs_train, ytrain, vectorizer= count_vec
                                      svd=True,
                                    model= RandomForestClassifier(random_state=0), doc

results_ml.loc['RF_count_bi_chi2'] = s_results(docs_train, ytrain, vectorizer= count_ve
                                    model= RandomForestClassifier(random_state=0), doc
```

In [67]:

```
# freq
results_ml.loc['RF_freq_uni'] = s_results(docs_train, ytrain, vectorizer= freq_vectoriz
                                          model= RandomForestClassifier(random_state=0), doc

results_ml.loc['RF_freq_uni_SVD'] = s_results(docs_train, ytrain, vectorizer= freq_vect
                                              svd=True,
                                          model= RandomForestClassifier(random_state=0), doc

results_ml.loc['RF_freq_uni_chi2'] = s_results(docs_train, ytrain, vectorizer= freq_vec
                                          model= RandomForestClassifier(random_state=0), doc

results_ml.loc['RF_freq_bi'] = s_results(docs_train, ytrain, vectorizer= freq_vectorize
                                          model= RandomForestClassifier(random_state=0), doc

results_ml.loc['RF_freq_bi_SVD'] = s_results(docs_train, ytrain, vectorizer= freq_vecto
                                             svd=True,
                                          model= RandomForestClassifier(random_state=0), doc

results_ml.loc['RF_freq_bi_chi2'] = s_results(docs_train, ytrain, vectorizer= freq_vect
                                          model= RandomForestClassifier(random_state=0), doc
```

In [68]:

```
# tfidf
results_ml.loc['RF_tfidf_uni'] = s_results(docs_train, ytrain, vectorizer= tfidf_vector
                                          model= RandomForestClassifier(random_state=0), doc

results_ml.loc['RF_tfidf_uni_SVD'] = s_results(docs_train, ytrain, vectorizer= tfidf_ve
                                               svd=True,
                                          model= RandomForestClassifier(random_state=0), doc

results_ml.loc['RF_tfidf_uni_chi2'] = s_results(docs_train, ytrain, vectorizer= tfidf_v
                                          model= RandomForestClassifier(random_state=0), doc

results_ml.loc['RF_tfidf_bi'] = s_results(docs_train, ytrain, vectorizer= tfidf_vectori
                                          model= RandomForestClassifier(random_state=0), doc

results_ml.loc['RF_tfidf_bi_SVD'] = s_results(docs_train, ytrain, vectorizer= tfidf_vec
                                              svd=True,
                                          model= RandomForestClassifier(random_state=0), doc

results_ml.loc['RF_tfidf_bi_chi2'] = s_results(docs_train, ytrain, vectorizer= tfidf_ve
                                          model= RandomForestClassifier(random_state=0), doc
```

In [69]:

```
# hash
results_ml.loc['RF_hash_uni'] = s_results(docs_train, ytrain, vectorizer= hashing_vecto
                                    model= RandomForestClassifier(random_state=0), doc

results_ml.loc['RF_hash_uni_SVD'] = s_results(docs_train, ytrain, vectorizer= hashing_v
                                       svd=True,
                                    model= RandomForestClassifier(random_state=0), doc

results_ml.loc['RF_hash_bi'] = s_results(docs_train, ytrain, vectorizer= hashing_vector
                                    model= RandomForestClassifier(random_state=0), doc

results_ml.loc['RF_hash_bi_SVD'] = s_results(docs_train, ytrain, vectorizer= hashing_ve
                                      svd=True,
                                    model= RandomForestClassifier(random_state=0), doc
```

modelo ML com melhor resultado

In [70]:

```
results_ml.sort_values(by=['mcc'], ascending=False).head(20)
```

Out[70]:

	acc	precision_macro	recall_macro	f1_macro	mcc
LG_binary_bi	0.8841	0.8903	0.8841	0.8850	0.8757
LG_count_bi	0.8837	0.8899	0.8837	0.8846	0.8752
SVM_tfidf_bi	0.8822	0.8907	0.8822	0.8835	0.8737
SVM_tfidf_uni_chi2	0.8816	0.8896	0.8816	0.8829	0.8731
SVM_freq_bi	0.8816	0.8900	0.8816	0.8828	0.8731
SVM_tfidf_bi_chi2	0.8816	0.8895	0.8816	0.8828	0.8730
SVM_tfidf_uni	0.8814	0.8894	0.8814	0.8826	0.8729
SVM_freq_uni	0.8811	0.8897	0.8811	0.8825	0.8726
SVM_freq_uni_chi2	0.8811	0.8896	0.8811	0.8825	0.8726
SVM_freq_bi_chi2	0.8811	0.8896	0.8811	0.8825	0.8726
RF_tfidf_uni	0.8806	0.8913	0.8806	0.8823	0.8723
RF_freq_uni	0.8804	0.8909	0.8804	0.8820	0.8721
RF_freq_bi	0.8801	0.8911	0.8801	0.8818	0.8717
RF_tfidf_bi_chi2	0.8803	0.8880	0.8803	0.8812	0.8717
RF_freq_bi_chi2	0.8801	0.8898	0.8801	0.8817	0.8717
RF_tfidf_uni_chi2	0.8801	0.8888	0.8801	0.8814	0.8716
SVM_count_bi	0.8799	0.8893	0.8799	0.8814	0.8714
RF_freq_uni_chi2	0.8796	0.8903	0.8796	0.8813	0.8712
SVM_binary_bi	0.8798	0.8890	0.8798	0.8813	0.8712
RF_tfidf_bi	0.8797	0.8887	0.8797	0.8810	0.8712

20 rows × 5 columns

Model Tuning

In [71]:

```
from sklearn.model_selection import GridSearchCV
```

In [72]:

```
vectorizer= binary_vectorizer2
docs_vect = vectorizer.fit_transform(docs_train)
```

In [73]:

```
grid = {'solver': ['liblinear','lbfgs','sag','saga'],
        'C': [10., 1.]}
grid_search = GridSearchCV(LogisticRegression(),
                           grid,
                           n_jobs=-1)
grid_search.fit(docs_vect, ytrain)
```

```
/home/00084776714/miniconda3/envs/tf/lib/python3.7/site-packages/sklearn/lin
ear_model/_sag.py:330: ConvergenceWarning: The max_iter was reached which me
ans the coef_ did not converge
  "the coef_ did not converge", ConvergenceWarning)
```

Out[73]:

```
GridSearchCV(estimator=LogisticRegression(), n_jobs=-1,
             param_grid={'C': [10.0, 1.0],
                         'solver': ['liblinear', 'lbfgs', 'sag', 'saga']})
```

In [74]:

```
grid_search.best_params_
```

Out[74]:

```
{'C': 10.0, 'solver': 'sag'}
```

In [75]:

```
model= LogisticRegression(**grid_search.best_params_)
pipe = Pipeline(steps=[('vectorizer', vectorizer),
                               ('model', model)])
pipe.fit(docs_train, ytrain)
```

```
/home/00084776714/miniconda3/envs/tf/lib/python3.7/site-packages/sklearn/lin
ear_model/_sag.py:330: ConvergenceWarning: The max_iter was reached which me
ans the coef_ did not converge
  "the coef_ did not converge", ConvergenceWarning)
```

Out[75]:

```
Pipeline(steps=[('vectorizer',
                 CountVectorizer(binary=True, ngram_range=(1, 2))),
                ('model', LogisticRegression(C=10.0, solver='sag'))])
```

In [76]:

```
yv_pred = pipe.predict(docs_val)
matthews_corrcoef(yval, yv_pred)
```

Out[76]:

```
0.8784409142350387
```

Salvando o melhor modelo de ML

In [77]:

```
# save ML best model
with open(r"../best_models/ML_model.pickle", 'wb') as handle:
    pickle.dump(pipe, handle)
```

Carregando o melhor modelo de ML

In [78]:

```
def load_doc(filename):
    ''' # load doc into memory '''
    # open the file as read only
    file = open(filename, 'r')
    # read all text
    text = file.read()
    # close the file
    file.close()
    return text
```

In [79]:

```
with open(r"../best_models/ML_model.pickle", 'rb') as handle:
    loaded_pipe = pickle.load(handle)
# vocabulario
loaded_vocab = load_doc(r'../best_models/vocab.txt')
```

In [80]:

```
yv_pred = loaded_pipe.predict(docs_val)
matthews_corrcoef(yval, yv_pred)
```

Out[80]:

```
0.8784409142350387
```

In [81]:

```
print(classification_report(yval, yv_pred, digits=4))
```

```
              precision    recall  f1-score   support

          25     0.8300    0.9030    0.8649      1000
          30     0.9850    0.9880    0.9865      1000
          40     0.9834    0.9490    0.9659      1000
          60     0.9692    0.9750    0.9721      1000
          70     0.9739    0.8970    0.9339      1000
          71     0.9836    0.9600    0.9717      1000
          72     0.9385    0.9920    0.9645      1000
          80     0.9930    0.9870    0.9900      1000
          90     0.7807    0.7440    0.7619      1000
         120     0.8961    0.8190    0.8558      1000
         130     0.8312    0.7240    0.7739      1000
         140     0.7120    0.6800    0.6957      1000
         200     0.9690    0.9060    0.9364      1000
         999     0.6535    0.8900    0.7536      1000

    accuracy                         0.8867     14000
   macro avg     0.8928    0.8867    0.8876     14000
weighted avg     0.8928    0.8867    0.8876     14000
```

In [82]:

```
# matriz de confuso: columns: True,  index:   Predict
cm = confusion_matrix(yval, yv_pred)
pd.DataFrame(data=cm, columns=np.sort(val.y.unique()), index=np.sort(val.y.unique()))
```

Out[82]:

	25	30	40	60	70	71	72	80	90	120	130	140	200	999
25	903	6	2	6	0	0	0	0	17	2	0	5	6	53
30	0	988	1	0	0	0	0	0	2	0	0	0	1	8
40	6	0	949	0	0	1	0	0	5	1	0	4	1	33
60	0	0	1	975	0	0	1	0	3	0	0	17	1	2
70	0	0	0	3	897	1	2	0	5	7	21	33	1	30
71	1	0	0	0	0	960	0	0	26	3	0	0	1	9
72	1	0	0	0	0	0	992	0	0	1	4	0	0	2
80	0	0	0	0	2	0	1	987	0	1	0	4	0	5
90	10	0	2	0	1	0	0	6	744	62	0	3	1	171
120	4	1	1	0	0	3	0	0	99	819	1	5	12	55
130	0	0	2	0	7	4	54	0	0	0	724	183	0	26
140	125	5	2	19	7	1	5	0	8	1	119	680	1	27
200	24	0	0	0	1	0	1	0	4	2	0	11	906	51
999	14	3	5	3	6	6	1	1	40	15	2	10	4	890

14 rows × 14 columns

```
90 = construçao civil CNAE grupos 412, 432, 433, 439
```

```
120 = construçao de obras de infraestrutura CNAE grupos 421, 422, 429, 431
isso explica a dificuldade de classificacao de atividades com servicos comuns
130 = operaçoes de carga, descarga e armazenagem de conteineres em portos organizados
140 = transporte rodoviario de cargas
```

```
Fiz a exclusao no treino dos registros com classe diferente de 999 (outros serviços
no sujeitos aliquota), sem informacao do codigo de serviço, e na lista: servico,
servicos, servicos prestados, prestacao servico
para forcar a classificacao em 999, cujo resultado  perceptvel na matriz de confusao
```

Fazendo predições ML:

In [83]:

```
def predict_ml_classe(lc, text, l_vocab, pipe):
    l_text_clean = clean_doc(text, False)
    l_text_clean = [w for w in l_text_clean if w in l_vocab]
    l_lc = list()
    lc_clean = re.sub(r'[^\w\s]', '', str(lc))
    if lc_clean in l_vocab:
        l_lc.append(lc_clean)
        l_lc.extend(l_text_clean)
        l_lc = [w for w in l_lc if w != '']
        return pipe.predict(l_lc)[0]
    return pipe.predict(l_text_clean)[0]
```

In [84]:

```
# Descrição de serviço de TI - classe 25
cd = ''
texto = 'desenvolvimento de sistemas'
classe = predict_ml_classe(cd,texto, loaded_vocab, loaded_pipe)
print(f'{texto}: classe {classe}')
```

```
desenvolvimento de sistemas: classe 25
```

In [86]:

```
# Descrição de serviço de hotelaria - classe 40
cd = ''
texto = 'hospedagem'
classe = predict_ml_classe(cd,texto, loaded_vocab, loaded_pipe)
print(f'{texto}: classe {classe}')
```

```
hospedagem: classe 40
```

In [87]:

```
# Descrição de serviço de obra de construo civil grupo CNAE 412, 432, 433,439 - classe
cd = ''
texto = 'obra de construção civil'
classe = predict_ml_classe(cd,texto, loaded_vocab, loaded_pipe)
print(f'{texto}: classe {classe}')
```

```
obra de construção civil: classe 90
```

In [88]:

```
# Descrição de serviço de carga, descarga e armazenagem - classe 130
cd = ''
texto = 'armazenagem'
classe = predict_ml_classe(cd,texto, loaded_vocab, loaded_pipe)
print(f'{texto}: classe {classe}')
```

```
armazenagem: classe 130
```

In [89]:

```
# Descrição de serviço prestado por empresas jornalsticas e de radiodifuso sonora - cla
cd = ''
texto = 'proganda em jornal'
classe = predict_ml_classe(cd,texto, loaded_vocab, loaded_pipe)
print(f'{texto}: classe {classe}')
```

```
proganda em jornal: classe 200
```

In [90]:

```
import sklearn
print(sklearn.__version__)
```

```
0.23.2
```

In [ ]:

```

```

In [1]:

```
import pickle
from joblib import dump, load
import re
import string
from nltk.corpus import stopwords
# sklearn.__version__ == 0.23.2
```

```
#conda install -c anaconda nltk
nltk.download('stopwords')
```

In [2]:

```
def clean_doc(doc=None, string_=True):
    ''' # turn a doc into clean tokens '''
    # split into tokens by white space
    tokens = doc.split()
    # prepare regex for char filtering
    re_punc = re.compile('[%s]' % re.escape(string.punctuation))
    # remove punctuation from each word
    tokens = [re_punc.sub('', w) for w in tokens]
    # remove remaining tokens that are not alphabetic
    tokens = [word.lower() for word in tokens if not word.isdigit()]
    # filter out stop words
    stop_words = set(stopwords.words('portuguese'))
    stop_words.update(['<br />'])
    tokens = [w for w in tokens if not w in stop_words]
    # filter out short tokens
    tokens = [word for word in tokens if len(word) > 1]
    if string_: return " ".join(tokens)
    else: return tokens

def load_doc(filename):
    ''' # load doc into memory '''
    # open the file as read only
    file = open(filename, 'r')
    # read all text
    text = file.read()
    # close the file
    file.close()
    return text

def predict_ml_classe(lc, text, l_vocab, pipe):
    l_text_clean = clean_doc(text, False)
    l_text_clean = [w for w in l_text_clean if w in l_vocab]
    l_lc = list()
    lc_clean = re.sub(r'[^\w\s]', '', str(lc))
    if lc_clean in l_vocab:
        l_lc.append(lc_clean)
        l_lc.extend(l_text_clean)
        l_lc = [w for w in l_lc if w != '']
        return pipe.predict(l_lc)[0]
    return pipe.predict(l_text_clean)[0]
```

In [3]:

```
with open(r"../best_models/ML_model.pickle", 'rb') as handle:
    loaded_pipe = pickle.load(handle)
# vocabulario
loaded_vocab = load_doc(r'../best_models/vocab.txt')
```

In [4]:

```
# Descrição de serviço de TI - classe 25
cd = ''
texto = 'desenvolvimento de sistemas'
classe = predict_ml_classe(cd,texto, loaded_vocab, loaded_pipe)
print(f'{texto}: classe {classe}')
```

```
desenvolvimento de sistemas: classe 25
```

In [5]:

```
# Descrição de serviço de hotelaria - classe 40
cd = ''
texto = 'hospedagem'
classe = predict_ml_classe(cd,texto, loaded_vocab, loaded_pipe)
print(f'{texto}: classe {classe}')
```

```
hospedagem: classe 40
```

In [6]:

```
# Descrição de serviço de obra de construo civil grupo CNAE 412, 432, 433,439 - classe
cd = ''
texto = 'obra de construção civil'
classe = predict_ml_classe(cd,texto, loaded_vocab, loaded_pipe)
print(f'{texto}: classe {classe}')
```

```
obra de construção civil: classe 90
```

In [ ]:

```

```